

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH  
TRƯỜNG ĐẠI HỌC BÁCH KHOA  
KHOA ĐIỆN - ĐIỆN TỬ  
BỘ MÔN VIỄN THÔNG  
CHƯƠNG TRÌNH KỸ SỰ CHẤT LƯỢNG CAO VIỆT PHÁP



LUẬN VĂN TỐT NGHIỆP

**HỆ THỐNG GIÁM SÁT VIỆC SỬ  
DỤNG THIẾT BỊ BẢO HỘ CÁ NHÂN  
ỨNG DỤNG MẠNG HỌC SÂU**

**NGUYỄN THÁI SƠN - 1512847**

**GIẢNG VIÊN HƯỚNG DẪN:  
PGS. TS. HÀ HOÀNG KHA**

*Thành phố Hồ Chí Minh, tháng 6 năm 2020*

Số: \_\_\_\_\_/BKDT  
Khoa: Điện - Điện tử  
Bộ môn: Viễn Thông

# NHIỆM VỤ LUẬN VĂN TỐT NGHIỆP

- |   |                 |
|---|-----------------|
| 1. HỌ VÀ TÊN: NGUYỄN THÁI SƠN   | MSSV: 1512847   |
| 2. NGÀNH: VIỄN THÔNG  | LỚP: VP15VT     |
| 3. Đề tài: <b>HỆ THỐNG GIÁM SÁT VIỆC SỬ DỤNG THIẾT BỊ BẢO HỘ CÁ NHÂN ỨNG DỤNG MẠNG HỌC SÂU</b>  |                 |
| 4. Nhiệm vụ (Yêu cầu về nội dung và số liệu ban đầu):   |                 |
| <ul style="list-style-type: none"> <li>• Tìm hiểu về CNN, mô hình YOLOv3 và cách ứng dụng của mô hình này vào việc nhận diện trang thiết bị bảo hộ lao động.</li> <li>• Xây dựng tập dữ liệu gồm các hình ảnh chứa người đội nón bảo hộ, mặc áo phản quang và đeo khẩu trang cùng với tệp tin nhãn dán của từng hình.</li> <li>• Huấn luyện mô hình nhận diện trên framework darknet và viết chương trình Python sử dụng mô hình đã huấn luyện để nhận diện.</li> <li>• Đánh giá các thông số hiệu năng của mô hình đối với các thiết bị bảo hộ trong các trường hợp thực tế, kết luận và viết luận văn.</li> </ul> |                 |
| 5. Ngày giao nhiệm vụ luận văn:   | .....           |
| 6. Ngày hoàn thành nhiệm vụ:  | .....           |
| 7. Họ và tên người hướng dẫn:   | Phàn hướng dẫn  |
| <b>.... PGS. TS. Hà Hoàng Kha ....</b>  | Toàn phần ..... |

Nội dung và yêu cầu LVTN đã được thông qua Bộ Môn.

Tp.HCM, ngày ... tháng ... năm 2020

## CHỦ NHIỆM BỘ MÔN

NGƯỜI HƯỚNG DẪN CHÍNH

## PHẦN DÀNH CHO KHOA, BỘ MÔN

Người duyệt (chấm sơ bộ):.....

Đơn vị:.....

Ngày bảo vệ:.....

Điểm tổng kết:.....

Nơi lưu trữ luân văn:.....

# LỜI CẢM ƠN

Khoảng thời gian học tập và rèn luyện tại **Trường Đại học Bách Khoa Thành phố Hồ Chí Minh** đã trang bị cho em rất nhiều kiến thức hữu ích và cần thiết về chuyên môn và xã hội để em có thể trở thành một công dân tốt và một kỹ sư có năng lực. Con đường học tập ở đại học trong suốt 5 năm vừa qua là không hề dễ dàng với muôn vàn thử thách và khó khăn. Để vượt qua những rào cản ấy, bên cạnh sự cố gắng của bản thân em còn là sự ủng hộ và giúp đỡ tận tình của quý **Thầy Cô, Gia đình và Bạn bè**. Em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến quý **Thầy Cô Trường Đại học Bách Khoa Thành phố Hồ Chí Minh**, quý **Thầy Cô Khoa Điện – Điện Tử**, những người đã đi cùng với tri thức và tâm huyết truyền đạt vốn kiến thức quý báu của mình cho chúng em.

Em muốn giành riêng lời cảm ơn đặc biệt cho Thầy hướng dẫn của mình – PGS. TS. Hà Hoàng Kha – người đã luôn tận tình hướng dẫn và giúp đỡ em trong quá trình thực hiện luận văn này.

Ngoài ra, em cũng muốn giành cho gia đình và bạn bè lời cảm ơn chân thành và đặc biệt là ba mẹ và ông bà em, những người đã luôn là chỗ dựa tinh thần vững chắc cho em trong những thời điểm khó khăn.

Trong quá trình thực hiện luận văn chắc chắn không thể tránh khỏi những sai sót, em rất mong nhận được những ý kiến đóng góp quý báu của quý Thầy Cô để em có thể học hỏi thêm những điều tốt đẹp và hoàn thiện luận văn của mình. Sau cùng, em xin kính chúc quý **Thầy Cô Trường Đại học Bách Khoa Thành phố Hồ Chí Minh** và **Thầy Hà Hoàng Kha** dồi dào sức khỏe, đạt được nhiều thành công trong cuộc sống và luôn giữ vững niềm đam mê nghiên cứu và giảng dạy để có thể tiếp tục truyền lửa tri thức cho những thế hệ sau.

Thành phố Hồ Chí Minh, tháng 6 năm 2020

Nguyễn Thái Sơn

# TÓM TẮT LUẬN VĂN

Ý tưởng về việc kết hợp trí tuệ nhân tạo và thị giác máy tính để ứng dụng vào các bài toán giám sát đã xuất hiện từ lâu. Tuy nhiên chỉ đến những năm gần đây khi các thiết bị phần cứng có thể đáp ứng được yêu cầu về tính kĩ thuật và kinh tế thì các ứng dụng sử dụng các công nghệ này mới dần trở nên phổ biến. Một trong những ứng dụng đang rất được quan tâm là đảm bảo an toàn lao động của công nhân xây dựng thông qua một hệ thống giám sát sử dụng camera và trí tuệ nhân tạo để theo dõi việc sử dụng các thiết bị bảo hộ lao động của những người làm việc trong công trường.

Trong khuôn khổ của luận văn này, hệ thống giám sát việc sử dụng thiết bị bảo hộ cá nhân sẽ tập trung vào ba thiết bị thường gặp trong công trường xây dựng: mũ cứng, áo dạ quang bảo hộ và khẩu trang. Hệ thống sử dụng phương pháp phát hiện và phân loại vật thể YOLO, được xây dựng trên cơ sở mạng tích chập - CNN. Khi hoạt động, hệ thống sẽ có thể phát hiện và phân loại việc sử dụng các thiết bị bảo hộ lao động của công nhân ở công trường. Nếu phát hiện một trường hợp không sử dụng thiết bị bảo hộ lao động đang được theo dõi thì hệ thống sẽ gửi cảnh báo cho quan sát viên để kiểm tra và nhắc nhở. Việc này sẽ hỗ trợ rất nhiều trong công tác đảm bảo an toàn lao động trong xây dựng.

Hệ thống được viết bằng ngôn ngữ Python, mô hình máy học YOLOv3 và thư viện thị giác máy tính OpenCV.

# Abstract

The idea of artificial intelligence and computer vision working together for surveillance has been around for a long time. However, only came in recent years when the computing hardware can meet the technical and economic requirements for application purpose that the usage of these technologies gradually becomes popular. One of the applications that gained tremendous amount of attention is ensuring the safety of the construction workers. Through a supervisory system of cameras with artificial intelligence as a detector to monitor the use of personal protective equipment of site workers.

In the context of this thesis, the system will focus on three common equipment at construction sites: hard hats, safety vest and face mask. The system uses YOLO, a CNN object detection algorithm. When operating, the system will be able to detect and categorize the use of personal protection equipment by workers at the construction site. If the system detects a case of non-use of personal protection equipment then the system will send alerts to the ones in charge of the site so that actions can be conducted before an irreversible accident happens. This will greatly improves the safety of working labors in construction site.

The system is written in Python using YOLOv3 machine learning model and open source computer vision library OpenCV.

# Mục lục

<b>1</b>	<b>Vấn đề trong khâu giám sát an toàn lao động và giải pháp ứng dụng trí tuệ nhân tạo</b>	<b>1</b>
1.1	Thực trạng trong việc thực hiện an toàn lao động ở Việt Nam và vấn đề của việc giám sát truyền thống . . . . .	1
1.2	Mục tiêu nghiên cứu . . . . .	2
1.3	Phạm vi nghiên cứu . . . . .	3
1.4	Phương pháp nghiên cứu . . . . .	3
1.5	Cấu trúc luận văn . . . . .	3
<b>2</b>	<b>Cơ sở lý thuyết về mạng neuron nhân tạo và mô hình YOLOv3</b>	<b>4</b>
2.1	Sự phát triển của trí tuệ nhân tạo . . . . .	4
2.2	Mạng neuron nhân tạo . . . . .	5
2.2.1	Ý tưởng về một neuron nhân tạo . . . . .	5
2.2.2	Mạng lưới các neuron . . . . .	7
2.2.3	Hàm mất mát và bài toán tối ưu mạng neuron . . . . .	9
2.3	Tối ưu hàm mất mát bằng Gradient Descent . . . . .	10
2.3.1	Một ví dụ đơn giản về Gradient Descent . . . . .	10
2.3.2	Gradient Descent cho hàm đa biến . . . . .	13
2.3.3	Điều kiện dừng của giải thuật . . . . .	13
2.4	Sử dụng backpropagation để giải quyết vấn đề cập nhật trọng số trong mạng neuron . . . . .	15
2.5	Mạng neuron tích chập . . . . .	17
2.5.1	Lớp tích chập . . . . .	17
2.5.2	Lớp pooling . . . . .	20
2.5.3	Lớp đầy đủ kết nối . . . . .	21
2.6	Mô hình YOLOv3 . . . . .	22
2.6.1	Unified Detection . . . . .	22
2.6.2	Kiến trúc mạng YOLOv3 . . . . .	24
<b>3</b>	<b>Xây dựng tập dữ liệu, huấn luyện và sử dụng mô hình YOLOv3 cho bài toán nhận diện thiết bị bảo hộ cá nhân</b>	<b>27</b>
3.1	Xây dựng tập dữ liệu cho bài toán nhận diện thiết bị bảo hộ cá nhân . . . . .	27
3.1.1	Xác định yêu cầu bài toán . . . . .	27
3.1.2	Thu thập hình ảnh và dán nhãn . . . . .	28
3.2	Huấn luyện mạng YOLOv3 sử dụng framework Darknet với tập dữ liệu riêng . . . . .	30
3.3	Sử dụng Python và mô hình mạng học sâu đã huấn luyện để nhận diện việc sử dụng trang thiết bị bảo hộ cá nhân trên camera hoặc video . . . . .	34

<b>4 Đánh giá các thông số hiệu năng của mô hình nhận diện trang thiết bị bảo hộ</b>	<b>43</b>
4.0.1 Thử nghiệm mô hình trong các trường hợp thực tế . . . . .	44
<b>5 Kết luận về khả năng nhận diện việc sử dụng trang thiết bị bảo hộ của mô hình và hướng phát triển</b>	<b>56</b>
5.1 Kết luận về khả năng nhận diện việc sử dụng trang thiết bị bảo hộ của mô hình . . . . .	56
5.2 Hướng phát triển . . . . .	57

# Danh sách hình vẽ

2.1	Mô hình một neuron sinh học. . . . .	5
2.2	Mô hình một neuron nhân tạo. . . . .	6
2.3	Đồ thị và đạo hàm của hàm Sigmoid. . . . .	6
2.4	Đồ thị và đạo hàm của hàm Tanh. . . . .	7
2.5	Đồ thị và đạo hàm của hàm Rectified Linear Unit. . . . .	7
2.6	Mô hình mạng neuron nhân tạo gồm 3 lớp hidden layer, 1 đầu vào và 1 đầu ra. . . . .	8
2.7	Mô hình toán của các lớp ẩn trong mạng neuron. . . . .	9
2.8	Cực tiểu địa phương (màu xanh) và cực tiểu toàn cục (màu đỏ) .	10
2.9	Batch Gradient Descent với bài toán hồi quy tuyến tính. Toàn bộ số điểm đầu vào đều được dùng để cập nhật các vector trọng số $(a, b)$ cho đường hồi quy tại mỗi bước, với $a$ là độ dốc và $b$ độ sai lệch. . . . .	11
2.10	Stochastic Gradient Descent với bài toán hồi quy tuyến tính. Một điểm đầu vào được chọn ngẫu nhiên để cập nhật các vector trọng số $(a, b)$ cho đường hồi quy tại mỗi iteration, với $a$ là độ dốc và $b$ độ sai lệch. . . . .	12
2.11	Mini-batch Gradient Descent với bài toán hồi quy tuyến tính. Một batch sẽ gồm ba điểm đầu vào được chọn ngẫu nhiên để cập nhật các vector trọng số $(a, b)$ cho đường hồi quy tại mỗi iteration, với $a$ là độ dốc và $b$ độ sai lệch. Một epoch sẽ gồm mươi batch. . . . .	13
2.12	Đồ thị mặt phẳng hàm mất mát và Gradient Descent cho hàm nhiều biến. . . . .	14
2.13	Mô hình mạng neuron tích chập đơn giản. Lớp nhận hình ảnh vào màu đỏ là một lớp có cấu trúc ba chiều với chiều rộng và chiều cao là chiều rộng và chiều cao của hình ảnh đầu vào, chiều sâu bằng ba ứng với ba kênh màu đỏ, xanh lá và xanh dương. Các lớp của mạng neuron tích chập sẽ chuyển đổi một nhóm các ma trận thành một nhóm các ma trận khác. Lớp ngoài cùng là lớp phân loại, có kích thước các chiều tương ứng với một vector. . . . .	17
2.14	Hình ảnh đầu vào gồm ba kênh màu được mô hình hóa thành tensor với chiều cao và chiều rộng là chiều cao và chiều rộng của ảnh, chiều sâu là ba. . . . .	18
2.15	Hình ảnh sau khi được đưa qua đầu vào và chuyển đổi thành dữ liệu ba chiều sẽ được đưa vào lớp convolution đầu tiên. Một kernel có kích thước $3 \times 3 \times 3$ (góc trên bên trái của mô hình ngoài cùng bên phải) được trượt qua hình đầu vào. . . . .	18
2.16	Ví dụ về phép toán của sổ trượt với kích thước $3 \times 3$ . . . . .	18

2.17	Bên trái, ma trận $3 \times 3$ được zero padding với $padding = 1$ . Bên phải, ma trận $3 \times 3$ được zero padding với $padding = 2$ . . . . .	19
2.18	Ví dụ về một kernel có kích thước $3 \times 3 \times 3$ . . . . .	19
2.19	Ví dụ về phép toán của một kernel lên một vị trí của ảnh trong lớp tích chập. . . . .	20
2.20	Một lớp tích chập có $k$ kernel với kích thước $3 \times 3 \times 3$ , $stride = 1$ , $padding = 1$ . Đầu vào là một tensor có kích thước $h \times w \times d$ đầu ra của phép tích chập lên tensor này khi khôi tích chập có các thông số ở trên là một tensor có kích thước $h \times w \times k$ . . . . .	20
2.21	Bên trái, lớp pooling với cửa sổ trượt lấy giá trị lớn nhất với kích thước cửa sổ $2 \times 2$ , $stride = 1$ , $padding = 0$ . Bên phải, lớp pooling với cửa sổ trượt lấy giá trị trung bình với kích thước cửa sổ $2 \times 2$ , $stride = 2$ , $padding = 0$ . . . . .	21
2.22	Mạng neuron tích chập gồm hai lớp tích chập và pooling, một lớp kết nối đầy đủ. . . . .	21
2.23	Hình ảnh được chia thành mạng lưới ô vuông $S \times S$ . . . . .	22
2.24	Miêu tả việc tính toán IOU. . . . .	23
2.25	Mô hình dự đoán bounding box của YOLO. . . . .	23
2.26	Kiến trúc mạng Darknet-53. . . . .	25
3.1	(1) Mũ bảo hộ, (2) Áo bảo hộ, (3) Khẩu trang . . . . .	27
3.2	Kết quả nhận dạng mong muốn. . . . .	28
3.3	Dịnh dạng nhãn của YOLO. . . . .	29
3.4	Thông kê số lượng vật thể ứng với từng class. Wearing a hardhat: 27565, Not wearing a hardhat: 45888, Wearing a safety vest: 10264, Not wearing a safety vest: 52996, Wearing a mask: 12557, Not wearing a mask: 46501. . . . .	29
3.5	Sơ đồ khôi chương trình Python để nhận dạng trên video hoặc webcam. . . . .	35
4.1	Số lượng các object trong tập dữ liệu validation. Wearing a hardhat - 2113, Not wearing a hardhat - 3313, Wearing a safety vest - 814, Not wearing a safety vest - 3900, Wearing a mask - 887, Not wearing a mask - 3492. . . . .	44
4.2	Precision - màu đỏ, Recall - màu xanh dương, Mean Average Precision - màu xanh lá. Các thông số được tính toán mỗi 1000 iteration trên tập dữ liệu validation. . . . .	45
4.3	Các chủ thể đứng cách camera ở khoảng cách 3m. . . . .	46
4.4	Các chủ thể đứng cách camera ở khoảng cách 6m. . . . .	46
4.5	Các chủ thể đứng cách camera ở khoảng cách 9m. . . . .	46
4.6	Một chủ thể đội nón vải trắng - bên trái và một chủ thể đội nón bảo hiểm trắng - bên phải. Góc chụp trực diện . . . . .	46
4.7	Một chủ thể đội nón vải trắng - bên trái và một chủ thể đội nón bảo hiểm trắng - bên phải. Góc chụp từ trái qua . . . . .	46
4.8	Precision của các class tại các khoảng cách 3m - màu đỏ, 6m - màu xanh và 9m - màu đen. Cao hơn nghĩa là tốt hơn. . . . .	47
4.9	Recall của các class tại các khoảng cách 3m - màu đỏ, 6m - màu xanh và 9m - màu đen. Cao hơn nghĩa là tốt hơn. . . . .	47
4.10	Dự đoán của mô hình ở khoảng cách 3m. . . . .	48

4.11 Mô hình có thể phân biệt tốt giữa nón vải trắng và nón bảo hiểm trắng ở khoảng cách 3m. . . . .	48
4.12 Dự đoán của mô hình ở khoảng cách 6m. . . . .	49
4.13 Mô hình có thể phân biệt tốt giữa nón vải trắng và nón bảo hiểm trắng ở khoảng cách 6m. . . . .	49
4.14 Dự đoán của mô hình ở khoảng cách 9m. . . . .	49
4.15 Mô hình không thể phân biệt tốt giữa nón vải trắng và nón bảo hiểm trắng ở khoảng cách 9m. . . . .	50
4.16 Chủ thẻ (bên trái) đeo khẩu trang không che kín mũi ở khoảng cách 3m. . . . .	50
4.17 Chủ thẻ (bên trái) đeo khẩu trang không che kín miệng ở khoảng cách 3m. . . . .	51
4.18 Kết quả dự đoán không tốt với chủ thẻ (bên trái) đeo khẩu trang không che kín mũi ở khoảng cách 3m. . . . .	51
4.19 Kết quả dự đoán tốt với chủ thẻ (bên trái) đeo khẩu trang không che kín miệng ở khoảng cách 3m. . . . .	52
4.20 Hai chủ thẻ (bên trái ngoài cùng) mặc áo bảo hộ sai cách ở khoảng cách 3m. . . . .	52
4.21 Kết quả dự đoán tốt với hai chủ thẻ mặc áo bảo hộ sai cách ở khoảng cách 3m. . . . .	53
4.22 Kết quả dự đoán tốt với hai chủ thẻ mặc áo bảo hộ sai cách (góc máy khác) ở khoảng cách 3m. . . . .	53
4.23 Kết quả dự đoán không tốt với hai chủ thẻ mặc áo bảo hộ sai cách ở khoảng cách 3m. . . . .	54
4.24 Hai chủ thẻ đúng sau vật cản ở khoảng cách 3m. . . . .	54
4.25 Precision của các class khi các chủ thẻ đúng sau vật cản và cách camera tại các khoảng cách 3m - màu đỏ và 6m - màu xanh. . . . .	55
4.26 Recall của các class khi các chủ thẻ đúng sau vật cản và cách camera tại các khoảng cách 3m - màu đỏ và 6m - màu xanh. . . . .	55

# Danh sách bảng

1.1	Số liệu về tình hình tại nạn lao động năm 2020. . . . .	1
1.2	Các nguyên nhân chính dẫn đến tai nạn chết người. . . . .	2
2.1	So sánh hiệu năng của Darknet-53 với các mạng khác. Accuracy, Bn Ops - billions of operations, BFLOP/s - billion floating point operations per second, và FPS - frames per second. . . . .	25

# Chương 1

## Vấn đề trong khâu giám sát an toàn lao động và giải pháp ứng dụng trí tuệ nhân tạo

### 1.1 Thực trạng trong việc thực hiện an toàn lao động ở Việt Nam và vấn đề của việc giám sát truyền thống

Ngành xây dựng luôn được coi là một trong những ngành ẩn chưa nhiều rủi ro về tai nạn lao động và khả năng mắc các bệnh nghề nghiệp. Trên thực tế nhiều vụ tai nạn nghiêm trọng đã xảy ra, lấy đi sinh mạng hoặc để lại những thương tật nặng nề cho người lao động khiến họ mất khả năng làm việc, sinh hoạt như người bình thường. Kéo theo đó là nỗi đau về tinh thần và gánh nặng về kinh tế cho những thành viên trong gia đình người bị nạn. Do đó vấn đề đảm bảo an toàn vệ sinh lao động luôn là một trong những vấn đề được quan tâm hàng đầu ở các cấp, các ngành. Theo báo cáo của 63/63 tỉnh, thành phố trực thuộc Trung ương[1], trong năm 2019, trên toàn quốc xảy ra **7130** vụ tai nạn lao động với **7267** người bị nạn với thống kê theo bảng 1.1.

Số người chết	610 người
Số vụ tai nạn lao động làm chết người	572 vụ
Số người bị thương nặng	1592 người
Nạn nhân là lao động nữ	2535 người
Số vụ tai nạn lao động có hai người bị nạn trở lên	119 vụ

Bảng 1.1: Số liệu về tình hình tai nạn lao động năm 2020.

Một trong những nguyên nhân chính gây ra những vụ tai nạn thương tâm là việc người lao động không sử dụng trang thiết bị bảo hộ cá nhân trong quá trình lao động. Vấn đề này không chỉ xuất phát từ sự chủ quan của cá nhân người lao động mà còn ở sự thiếu sót, lỏng lẻo trong quá trình giám sát công trình của nhà thầu và người sử dụng lao động. Bảng 1.2 cho thấy các nguyên nhân chính dẫn đến tai nạn lao động gây chết người trong năm 2019.

<i>Nguyên nhân</i>	<i>% tổng số vụ</i>	<i>% tổng số người chết</i>
<i>Do người sử dụng lao động</i>	<i>47.74</i>	<i>49.99</i>
<b>Người sử dụng lao động không xây dựng quy trình, biện pháp làm việc an toàn</b>	<b>24.32</b>	<b>26.27</b>
<i>Người sử dụng lao động không huấn luyện an toàn lao động hoặc huấn luyện an toàn, vệ sinh lao động chưa đầy đủ cho người lao động</i>	<i>14.41</i>	<i>13.56</i>
<i>Do tổ chức lao động và điều kiện lao động</i>	<i>7.21</i>	<i>8.47</i>
<i>Thiết bị không đảm bảo an toàn lao động</i>	<i>1.8</i>	<i>1.69</i>
<b><i>Do người lao động vi phạm quy trình quy chuẩn an toàn lao động</i></b>	<b><i>14.41</i></b>	<b><i>14.41</i></b>
<i>Nguyên nhân khách quan khác, khó tránh</i>	<i>37.85</i>	<i>35.6</i>

Bảng 1.2: Các nguyên nhân chính dẫn đến tai nạn chết người.

Dối với người lao động, những điều kiện khắc nghiệt của môi trường làm việc như nhiệt độ ngoài trời cao hay thường xuyên phải vận động mạnh khiến đổ mồ hôi liên tục đã khiến họ chấp nhận đánh đổi sự an toàn của bản thân để đổi lấy sự thoái mái. Còn đối với những người giám sát công trình, họ không thể bao quát được toàn bộ quá trình làm việc tại các nơi làm việc khác nhau, do đó không thể nhắc nhở người lao động kịp thời trước khi xảy ra những tai nạn mà hậu quả là có thể tránh khỏi hoặc được giảm nhẹ nếu người lao động có sử dụng trang thiết bị bảo hộ cá nhân.

Để tăng cường năng lực thực hiện đảm bảo an toàn vệ sinh lao động ở các công trình, nhiều chủ đầu tư và nhà thầu đã tiến hành lắp đặt các hệ thống camera giám sát quá trình làm việc. Các hệ thống này giúp giám sát viên có thể quan sát nhiều vị trí một lúc mà không cần phải di chuyển qua các địa điểm khác nhau trong công trình, giảm thiểu chi phí và thời gian thực hiện các công tác an toàn. Tuy nhiên, khi số lượng các khu vực cần quan sát tăng lên hoặc những người chịu trách nhiệm quan sát không tập trung vào nhiệm vụ thì việc giám sát thông qua màn hình dễ xảy ra sai sót. Việc tích hợp công nghệ AI vào các hệ thống giám sát sẽ là sẽ tăng thêm độ tin cậy cho công tác đảm bảo an toàn, giảm thiểu những sai sót không đáng có.

## 1.2 Mục tiêu nghiên cứu

Mục tiêu của luận văn là xây dựng, đánh giá một hệ thống nhận diện việc sử dụng thiết bị bảo hộ cá nhân của người lao động trong công trường để hỗ trợ cho các giám sát viên trong các đảm bảo an toàn lao động.

## 1.3 Phạm vi nghiên cứu

Phạm vi của luận văn là tiến hành nhận dạng trên các video trích xuất từ camera. Mô hình nhận diện được huấn luyện sử dụng framework được xây dựng sẵn. Tập dữ liệu sử dụng để huấn luyện và đánh giá mô hình nhận diện được thu thập và dán nhãn bởi người làm luận văn. Một phần hình ảnh trong tập dữ liệu này có nguồn gốc từ các tập dữ liệu khác nhưng không sử dụng lại các nhãn của các tập dữ liệu đó. Các thiết bị bảo hộ cá nhân được tích hợp trong hệ thống gồm: mũ cứng, áo bảo hộ và khẩu trang.

## 1.4 Phương pháp nghiên cứu

Các giai đoạn trong quá trình nghiên cứu và hoàn thiện luận văn:

1. Tìm hiểu về CNN, mô hình YOLOv3 và cách ứng dụng của mô hình này vào việc nhận diện trang thiết bị bảo hộ lao động.
2. Xây dựng tập dữ liệu gồm các hình ảnh chứa người đội nón bảo hộ, mặc áo phản quang và đeo khẩu trang cùng với tệp tin nhãn dán của từng hình.
3. Huấn luyện mô hình nhận diện trên framework darknet và viết chương trình Python sử dụng mô hình đã huấn luyện để nhận diện.
4. Đánh giá các thông số hiệu năng của mô hình đối với các thiết bị bảo hộ trong các trường hợp thực tế, kết luận và viết luận văn.

YOLOv3 được chọn để làm mô hình nhận diện vì đây là một trong số các bộ nhận diện có hiệu năng cao trong thời gian thực, đã được sử dụng và đánh giá trên nhiều tập dữ liệu khác nhau.

## 1.5 Cấu trúc luận văn

Luận văn này bao gồm 5 chương. Chương 1 là chương mở đầu, giới thiệu bao quát về vấn đề, mục tiêu, phạm vi và phương pháp nghiên cứu luận văn. Chương 2 sẽ cung cấp những lý thuyết về các khái niệm được sử dụng trong luận văn. Chương 3 cho người đọc biết về cách tập dữ liệu được xây dựng, cách mô hình YOLOv3 được huấn luyện sử dụng framework darknet và cách xây dựng hệ thống sử dụng mô hình nhận diện. Chương 4 sẽ chứa những thông số đánh giá hiệu năng của bộ nhận diện và hệ thống trong các trường hợp khác nhau. Cuối cùng, trong chương 5 sẽ là các nhận xét về các kết quả đạt được và kết luận.

## Chương 2

# Cơ sở lý thuyết về mạng neuron nhân tạo và mô hình YOLOv3

Chương này sẽ trình bày các lý thuyết về neuron và mạng neuron nhân tạo, vai trò của việc tối ưu hàm mất mát của một mạng neuron và cách mà một mạng neuron sử dụng giải thuật Gradient Descent kết hợp với kỹ thuật backpropagation để tối ưu hàm mất mát. Đồng thời lý thuyết về mạng neuron tích chập và ứng dụng của mạng này trong mạng YOLOv3 cũng sẽ được đề cập trong chương này để phục vụ cho các chương tiếp theo.

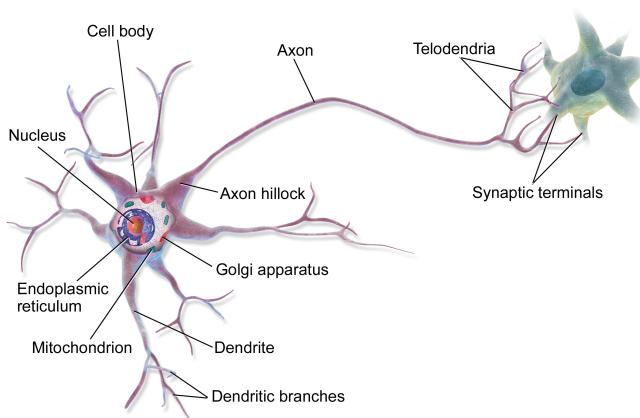
## 2.1 Sự phát triển của trí tuệ nhân tạo

Việc nghiên cứu và mô phỏng cách mà não bộ con người hoạt động trên máy tính đã bắt đầu từ những năm 50 của thế kỷ XX. Những nghiên cứu mang tính đột phá như *The organization of behavior*[2] của Donald Olding Hebb, *Some Studies in Machine Learning Using the Game of Checkers*[3] của Arthur Lee Samuel đã đặt nền móng cho những mô hình mạng neuron đa lớp nhân tạo đầu tiên trong những năm 60 của thế kỷ XX, mở ra những hướng nghiên cứu mới về các kiến trúc mạng neuron feedforward. Sau đó vào những năm 70 lý thuyết về backpropagation bắt đầu được hình thành nhằm cho phép mạng neuron đa lớp có thể điều chỉnh các lớp ẩn để thích nghi với các tình huống khác nhau dựa vào hàm mất mát ở đầu ra. Tuy nhiên chỉ đến khi bài báo nổi tiếng của nhóm tác giả David Rumelhart, Geoffrey Hinton và Ronald Williams được công bố thì việc sử dụng backpropagation trong mạng neuron nhân tạo mới trở nên phổ biến. Bài báo *Learning representations by back-propagating errors*[4] công bố năm 1986 của nhóm tác giả đã đề xuất một số mô hình mạng neuron sử dụng backpropagation có thể học và xử lý nhanh hơn các mô hình truyền thống, điều này cho phép mạng neuron nhân tạo sử dụng backpropagation có thể giải quyết được những bài toán mà đối với mạng neuron truyền thống là không có lời giải. Năm 1989, Yann LeCun, Léon Bottou, Yoshua Bengio và Patrick Haffner trong bài báo *Gradient-Based Learning Applied to Document Recognition*[5] đã kết hợp kỹ thuật backpropagation vào mạng neuron tích chập để giải quyết bài toán nhận diện chữ viết tay và phát hiện khuôn mặt. Bài báo này đã tạo tiền đề cho những nghiên cứu khác về mạng neuron tích chập và mạng neuron dựa trên gradient trong thế kỷ XXI.

## 2.2 Mạng neuron nhân tạo

### 2.2.1 Ý tưởng về một neuron nhân tạo

Neuron[6] là một tế bào thần kinh cơ bản, cấu thành nên hệ thần kinh của con người. Trung bình một bộ não người sẽ có 86 tỷ neuron và  $10^{14} - 10^{15}$  synapse. Hình 2.1 miêu tả các thành phần một neuron trong não người. Mỗi neuron sẽ nhận tín hiệu đầu vào từ các sợi nhánh (tiếng Anh: dendrite(s)) và gửi tín hiệu ra thông qua một sợi trực (tiếng Anh: axon). Sợi trực sẽ kết nối với các synapse và các synapse sẽ kết nối với các sợi nhánh của các neuron khác để gửi tín hiệu. Hình 2.2 miêu tả mô hình toán học của một neuron. Tín hiệu  $x_0$  đi qua sợi trực

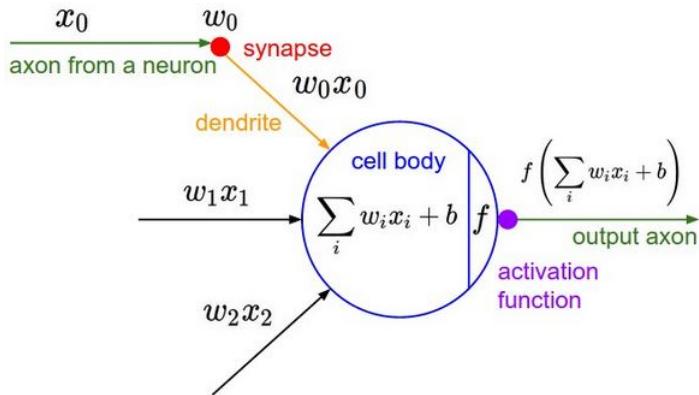


Hình 2.1: Mô hình một neuron sinh học.

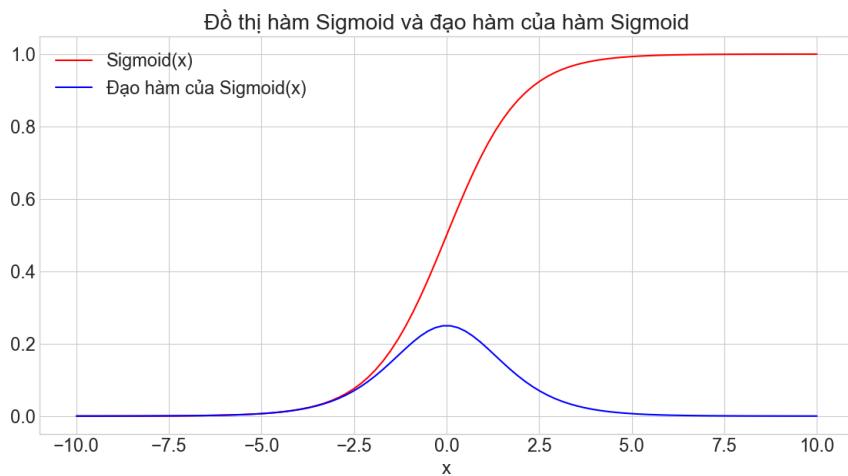
và tới synapse nơi kết nối với các sợi nhánh, mỗi sợi nhánh sẽ có một lực synapse (tiếng Anh: synaptic strength) được mô hình hóa bằng trọng số  $w$  biểu thị mức độ ảnh hưởng của sợi nhánh đó đến tín hiệu truyền đến neuron tiếp theo. Lực synapse có thể được học và điều chỉnh sự ảnh hưởng của neuron này đến neuron khác. Các tín hiệu sau khi đi qua sợi nhánh sẽ có dạng  $wx$  và sẽ được tổng hợp bằng hàm cộng trong tế bào neuron. Nếu như kết quả cao hơn một ngưỡng xác định thì tế bào neuron sẽ gửi tín hiệu đi. Hoạt động này được mô hình hóa bằng một hàm kích (tiếng Anh: activation function)  $f$  và cũng giống như mạng neuron sinh học, đầu ra sẽ chỉ là một kết quả duy nhất để gửi đến synapse kế tiếp.

Một số hàm số thường được sử dụng làm hàm kích cho một neuron nhân tạo gồm:

- Hàm sigmoid  $\sigma(x) = \frac{1}{1+e^{-x}}$ . Có thể thấy trên hình 2.3 đồ thị của hàm sigmoid, với mọi giá trị của  $x$  trên miền  $\mathbb{R}$  sau khi đi qua hàm sigmoid thì kết quả sẽ là một giá trị nằm trong khoảng  $[0, 1]$ . Đây là một trong những hàm số thường được sử dụng trong các mô hình mạng neuron cổ điển vì tính phi tuyến và khả năng mô hình hóa tương đối tốt quá trình một neuron gửi tín hiệu với cận 0 tương trưng cho tín hiệu không được truyền đi và cận 1 tương trưng cho tín hiệu được truyền đi. Tuy nhiên ta có thể thấy trên hình 2.3 hàm sigmoid có đạo hàm xấp xỉ bằng 0 tại các biên 0 và 1. Điều này ảnh hưởng tới việc sử dụng phương pháp backpropagation vì trong quá trình backpropagation thì đạo hàm của hàm kích sẽ được nhân với giá trị gradient của đầu ra tại neuron này, khi đó kết quả thu được có thể bằng 0



Hình 2.2: Mô hình một neuron nhân tạo.

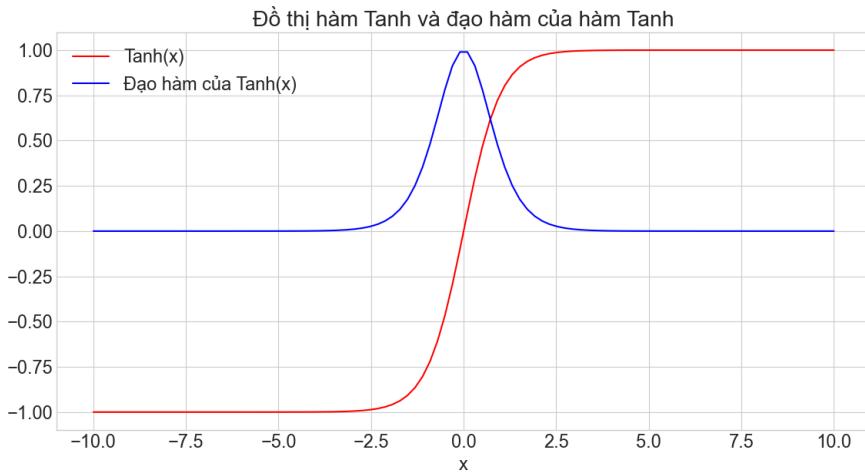


Hình 2.3: Đồ thị và đạo hàm của hàm Sigmoid.

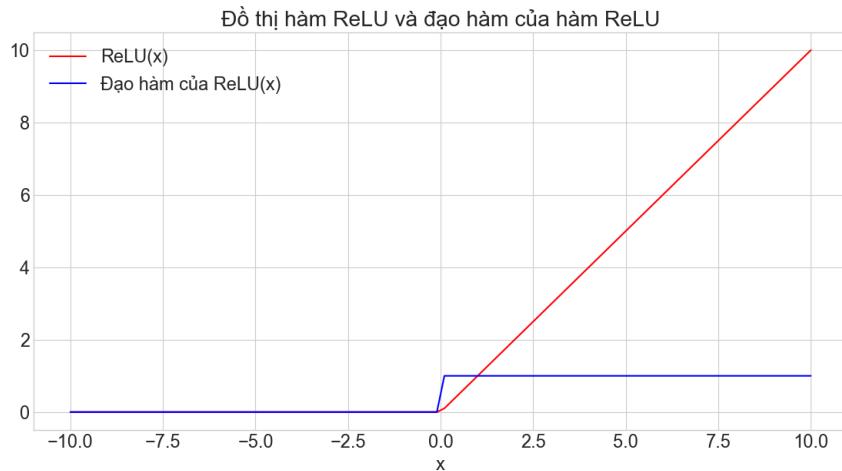
nếu kết quả đầu ra của neuron xấp xỉ 0 hoặc 1 và các trọng số kết nối với neuron này sẽ không được cập nhật. Ngoài ra kết quả của hàm sigmoid sẽ đổi xứng quanh 0.5 nên sẽ gây ra hiện tượng kết quả của gradient đổi dấu liên tục trong quá trình tính toán.

- Hàm tanh  $\tanh(x) = 2\sigma(2x) - 1$ . Hình 2.4 cho thấy hàm số này cũng có đạo hàm bằng 0 tại các biên 0 và 1 như hàm sigmoid nhưng kết quả của hàm tanh sẽ đổi xứng quanh điểm 0. Do vậy hàm tanh thường được ưu tiên dùng thay cho hàm sigmoid.
- Hàm Rectified Linear Unit với  $ReLU(x) = \max(0, x), x \in \mathbb{R}$ . Hình 2.5 miêu tả đồ thị hàm Rectified Linear Unit, khi sử dụng hàm số này, neuron sẽ cho kết quả đầu ra luôn dương tại ngưỡng 0. Hàm số này càng ngày càng được sử dụng nhiều trong các kiến trúc mạng neuron vì những ưu điểm như có khả năng tăng tốc độ hội tụ của một mô hình sử dụng gradient descent nhanh hơn gấp 6 lần[7] so với hàm sigmoid/tanh. Đồng thời việc tính toán đối với hàm số này cũng đơn giản hơn rất nhiều so với hàm sigmoid và tanh.

Về bản chất một neuron có thể đóng vai trò như một bộ phân loại nhị phân,



Hình 2.4: Đồ thị và đạo hàm của hàm Tanh.



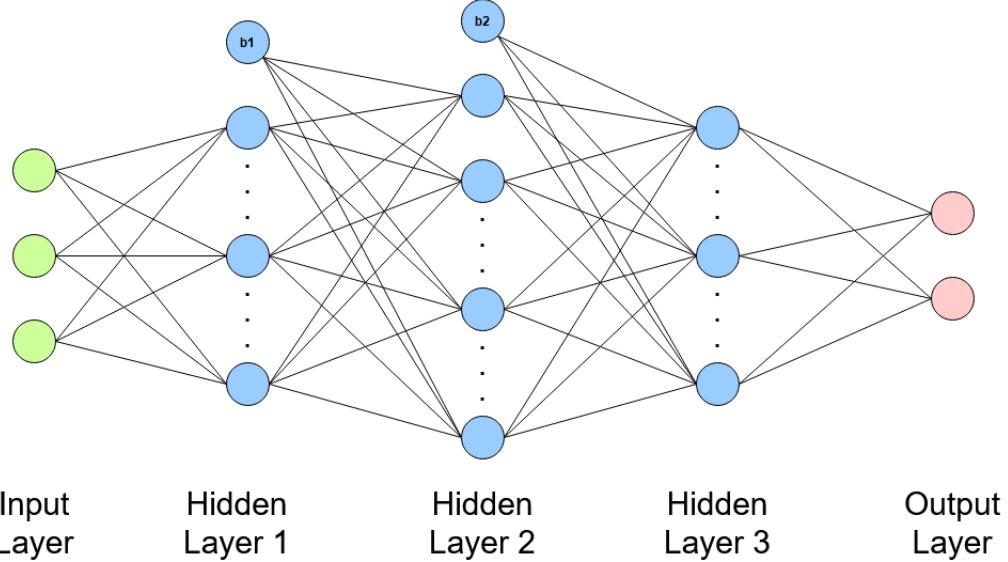
Hình 2.5: Đồ thị và đạo hàm của hàm Rectified Linear Unit.

tuy nhiên đối với các bài toán phức tạp, việc sử dụng một neuron đơn lẻ là bất khả thi. Để giải quyết các bài toán này, cần thiết phải có một mạng lưới gồm nhiều neuron liên kết với nhau. Đây cũng chính là nguồn cảm hứng cho nhiều nghiên cứu về các mô hình mạng neuron mở ra nhiều tiềm năng ứng dụng của trí tuệ nhân tạo trong cuộc sống.

### 2.2.2 Mạng lưới các neuron

Khác với mạng neuron sinh học, mạng neuron nhân tạo thường được tổ chức thành các lớp. Hình 2.6 thể hiện cấu trúc của một mạng neuron nhân tạo đơn giản. Lớp đầu tiên là lớp đầu vào (tiếng Anh: input layer) được dùng để lấy dữ liệu đầu vào cho mạng neuron. Lớp sau cùng là lớp đầu ra (tiếng Anh: output layer), lớp này sẽ cho ra kết quả tính toán sau cùng của các class cần được dự đoán với dữ liệu đầu vào tương ứng. Các lớp ở giữa được gọi là lớp ẩn (tiếng Anh: hidden layer) chứa các neuron có hàm kích và các liên kết có trọng số, đây chính là các lớp phụ trách việc trích xuất các đặc trưng và phân loại tín hiệu đầu vào.

Việc học của mạng neuron do vậy cũng diễn ra tại các lớp ẩn. Ta có thể thấy các neuron trong cùng một lớp thì không liên kết với nhau, ngoài ra mỗi neuron của lớp trước sẽ kết nối với mọi neuron của lớp sau ngoại trừ bias. Do đó các lớp này còn được gọi là các lớp kết nối hoàn toàn (tiếng Anh: fully connected layer).



Hình 2.6: Mô hình mạng neuron nhân tạo gồm 3 lớp hidden layer, 1 đầu vào và 1 đầu ra.

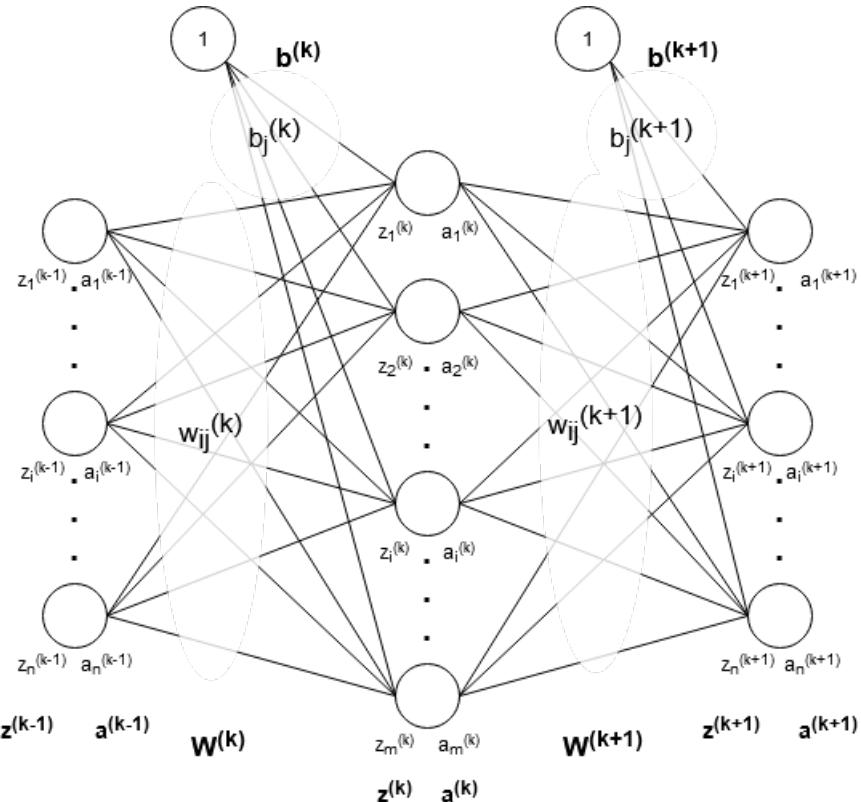
Quá trình mạng neuron nhân tạo lấy dữ liệu từ lớp đầu vào, đẩy dữ liệu qua các lớp ẩn và trả kết quả ở lớp đầu ra được gọi là quá trình *feed-forward*. Hình 2.7 và hệ phương trình 2.1 miêu tả mô hình toán học tổng quát của các lớp ẩn trong quá trình feed-forward của một mạng neuron.

$$\begin{aligned}
 a^{(0)} &= x \\
 z^{(k)} &= \mathbf{W}^{(k)T} a^{(k-1)} + \mathbf{b}^{(k)}, k = 1, 2, \dots, N \\
 a^{(k)} &= f^{(k)}(z^{(k)}), k = 1, 2, \dots, N \\
 \hat{y} &= a^{(N)}
 \end{aligned} \tag{2.1}$$

Với  $\mathbf{W}^{(k)}$  là ma trận trọng số của các liên kết giữa lớp thứ  $k - 1$  và lớp thứ  $k$ ,  $\mathbf{b}^{(k)}$  là vector bias của lớp thứ  $k$ ,  $z^{(k)}$  là vector đầu vào lớp ẩn thứ  $k$ ,  $a^{(k)}$  là vector đầu ra của lớp ẩn thứ  $k$ . Trong quá trình feed-forward, xét neuron thứ  $i$  của lớp thứ  $k - 1$  với kết quả đầu ra  $a_i^{(k-1)}$ , đầu vào  $z_j^{(k)}$  của neuron thứ  $j$  ở lớp thứ  $k$  là tổng tích các đầu ra ở lớp thứ  $k - 1$  với các trọng số  $w_{ij}^{(k)}$  cộng với bias  $b_j^{(k)}$  như phương trình

$$z_j^{(k)} = \sum_i a_i^{(k-1)} \times w_{ij}^{(k)} + b_j^{(k)}. \tag{2.2}$$

Sau đó với mỗi giá trị đầu vào  $z_i^{(k)}$  của một neuron thứ  $i$  của lớp thứ  $k$  ta sẽ có giá trị đầu ra của neuron là  $a_i^{(k)} = f^{(k)}(z_i^{(k)})$  với  $f^{(k)}$  là hàm kích của các neuron ở lớp thứ  $k$ . Quá trình này xảy ra liên tục giữa các lớp ẩn trong mạng neuron, do đó kết quả ở lớp đầu ra  $\hat{y} = a^{(N)}$  với một dữ liệu đầu vào  $a^{(0)} = x$  phụ thuộc vào các  $\mathbf{W}^{(k)}$  và  $\mathbf{b}^{(k)}$ . Ban đầu các ma trận trọng số và vector bias được khởi tạo một



Hình 2.7: Mô hình toán của các lớp ẩn trong mạng neuron.

cách ngẫu nhiên hoặc theo một quy luật định trước, tuy nhiên kết quả dự đoán của mạng neuron với các giá trị khởi tạo này sẽ không chính xác cũng như con người không thể thuần thực một thao tác ngay lập tức mà phải trải qua một quá trình học, ý tưởng cho việc học của một mạng neuron là với mỗi giá trị đầu vào, sau quá trình feed-forward, mạng neuron nhân tạo có thể đánh giá được mức độ chính xác của việc tính toán ở các lớp ẩn và điều chỉnh các ma trận trọng số và vector bias để tăng độ chính xác hay nói cách khác là tối thiểu hóa độ sai lệch giữa kết quả dự đoán và kết quả thật sự.

### 2.2.3 Hàm mất mát và bài toán tối ưu mạng neuron

Để đánh giá được sự sai lệch giữa kết quả dự đoán được và kết quả thật sự, các mô hình mạng neuron sử dụng khái niệm hàm mất mát  $J(\mathbf{W}, \mathbf{b}, \mathbf{X}, \mathbf{Y})$  (tiếng Anh: loss function). Một trong những hàm mất mát thường được sử dụng trong các mô hình mạng neuron nhân tạo cổ điển là hàm trung bình bình phương sai số (tiếng Anh: mean square error - MSE)

$$J(\mathbf{W}, \mathbf{b}, \mathbf{X}, \mathbf{Y}) = \frac{1}{M} \sum_{i=1}^M \|y_i - \hat{y}_i\|_2^2 = \frac{1}{M} \sum_{i=1}^M \|y_i - a_i^{(N)}\|_2^2. \quad (2.3)$$

Giả sử ta đang xét tới bài toán phân loại nhị phân với  $M = 2$ , đầu ra mong muốn của ta là  $(a^{(N)}_1, a^{(N)}_2) = (0.9, 0.1)$ . Lần thứ nhất mô hình dự đoán cho ra hai kết quả đầu ra là  $(y_1, y_2) = (0.6, 0.4)$  lúc này  $J = \frac{1}{2} (\|0.6 - 0.9\|_2^2 + \|0.4 - 0.1\|_2^2) = 0.09$ . Lần thứ hai mô hình dự đoán cho ra hai kết quả đầu ra là  $(y_1, y_2) =$

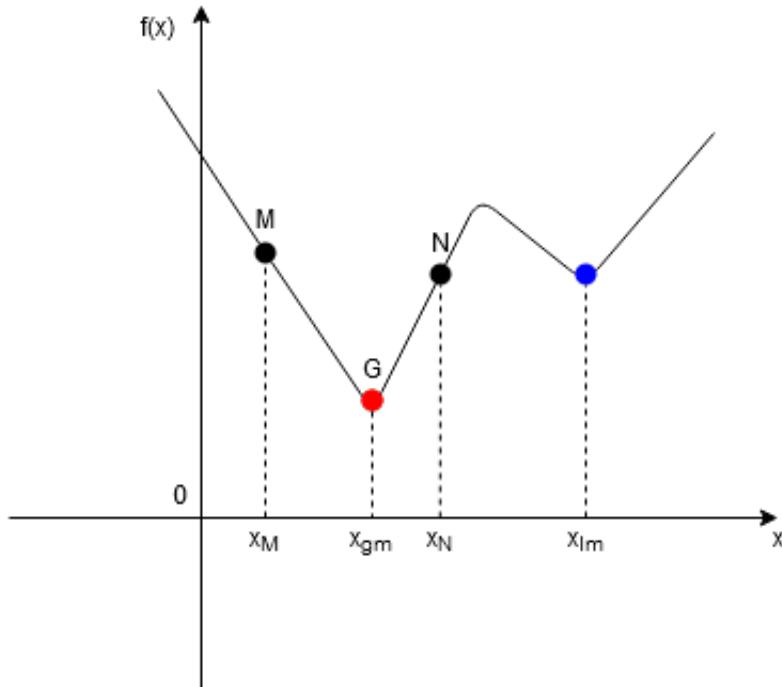
$(0.85, 0.15)$  lúc này  $J = \frac{1}{2} (\|0.85 - 0.9\|_2^2 + \|0.15 - 0.1\|_2^2) = 0.0025$ . Ta thấy rằng nếu như dự đoán của mô hình càng gần kết quả mong muốn thì giá trị của  $J$  sẽ càng nhỏ. Việc học của mô hình máy học về bản chất chính là việc tối thiểu hóa các giá trị đầu ra của hàm mất mát. Do  $J$  phụ thuộc vào các trọng số  $w_i^{(k)}$  và các bias  $b_j^{(k)}$  nên sau khi đánh giá được mức độ chính xác của dự đoán, mạng neuron nhân tạo sẽ tiến hành điều chỉnh các giá trị này nhằm làm giảm giá trị  $J$  trong các lần tính sau. Phương pháp được dùng để thực hiện việc tối thiểu hàm mất mát là Gradient Descent.

## 2.3 Tối ưu hàm mất mát bằng Gradient Descent

Để có thể hiểu cách mà Gradient Descent[8, p.158-174] được dùng để tối thiểu hàm mất mát của một mô hình mạng neuron nhân tạo. Ta sẽ bắt đầu bằng một ví dụ đơn giản về Gradient Descent với một hàm số đơn biến, sau đó mở rộng ra cho hàm số đa biến.

### 2.3.1 Một ví dụ đơn giản về Gradient Descent

Một hàm số có thể có nhiều điểm cực tiểu địa phương (local minimum) và cực tiểu toàn cục (global minimum). Ta có thể thấy trên hình 2.8 là đồ thị của một hàm số đơn biến, điểm màu xanh là cực tiểu địa phương, điểm màu đỏ là cực tiểu toàn cục. Giả sử ta có hai điểm  $M$  tại  $x_M$  và  $N$  tại  $x_N$  trên đồ thị hình



Hình 2.8: Cực tiểu địa phương (màu xanh) và cực tiểu toàn cục (màu đỏ)

2.8, ta gọi điểm cực tiểu toàn cục là  $G$ . Lúc này ta muốn đưa điểm  $M$  và  $N$  về xấp xỉ hoặc trùng với vị trí của  $G$  bằng giải thuật Gradient Descent. Ta nhận thấy  $M$  nằm bên trái  $G$  và  $f'(x_M) < 0$ , nếu  $M$  muốn di chuyển về phía  $G$  thì

$x_{M_{k+1}} = x_{M_k} + \delta$  tại bước thứ  $k + 1$ . Ngược lại nếu ta muốn  $N$  có  $f'(x_N) > 0$  tiến về phía  $G$  tại bước tính toán thứ  $k + 1$  thì  $x_{N_{k+1}} = x_{N_k} - \delta$ . Như vậy để một điểm bắt kì  $(x, f(x))$  lân cận  $G$  trên đồ thị tiến về  $G$  thì vị trí của điểm đó phải được cập nhật sau mỗi bước tính toán bằng cách cộng với một lượng  $\delta$  với  $sign(\delta) = -sign(f'(x))$ . Trong thực tế, công thức được sử dụng có dạng:

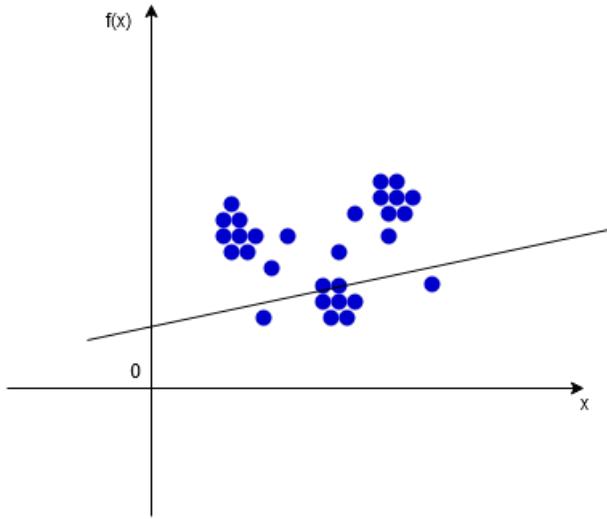
$$x_{k+1} = x_k - \mu f'(x_k) \quad (2.4)$$

Với  $\mu$  là *tốc độ học*,  $\mu \in \mathbb{R}$ ,  $\mu > 0$ . Nếu ta chọn  $\mu$  lớn thì ta sẽ cần ít số bước tính toán hơn để đến gần vị trí cực tiểu mong muốn nhưng trong nhiều trường hợp độ sai lệch giữa vị trí của điểm tính toán được sau cùng và vị trí của điểm cực tiểu sẽ tương đối cao. Ngược lại, nếu ta chọn  $\mu$  nhỏ thì ta sẽ cần nhiều hơn số bước tính toán, bù lại khoảng cách giữa vị trí điểm tính toán được sau cùng và vị trí điểm cực tiểu sẽ có thể rất nhỏ.

Hiện nay có ba phương pháp thuộc họ Gradient Descent đang được sử dụng:

### 1. Batch Gradient Descent

Giải thuật Batch Gradient Descent sử dụng tất cả các điểm đầu vào để cập nhật lại vector trọng số tại mỗi bước. Giả sử ta cần tối ưu hàm mất mát của một bài toán hồi quy tuyến tính gồm 30 điểm đầu vào với mỗi điểm gồm 2 tham số  $(x, f(x))$  ở hình 2.9. Để tìm gradient cho mỗi điểm ta cần thực hiện 2 phép toán theo toán tử  $\nabla$ , đồng thời ta phải tìm gradient cho cả 30 điểm tại mỗi bước lặp và lấy trung bình của các kết quả này để cập nhật trọng số. Tổng số phép toán mà ta phải thực hiện cho tại mỗi bước là  $30 \times 2 = 60$ . Con số này sẽ tăng lên gấp nhiều lần đối với các bài toán thực tế khi số điểm và số tham số là vài triệu hoặc vài tỷ. Nói cách khác thuật toán này không hiệu quả về mặt tính toán với các bài toán máy học với dữ liệu lớn và phải cập nhật liên tục. Ngoài ra sau khi đã tìm được nghiệm tối

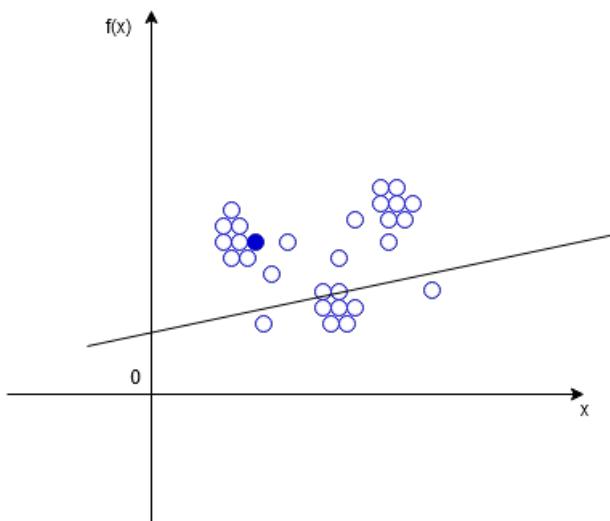


Hình 2.9: Batch Gradient Descent với bài toán hồi quy tuyến tính. Toàn bộ số điểm đầu vào đều được dùng để cập nhật các vector trọng số  $(a, b)$  cho đường hồi quy tại mỗi bước, với  $a$  là độ dốc và  $b$  độ sai lệch.

ưu của bài toán. Nếu ta thêm một điểm đầu vào mới vào tập dữ liệu cũ thì việc tính toán phải thực hiện lại từ đầu với toàn bộ điểm đầu vào bao gồm tập điểm đầu vào cũ và điểm mới thêm vào.

## 2. Stochastic Gradient Descent

Khác với Batch Gradient Descent giải thuật Stochastic Gradient Descent chỉ dùng gradient của một điểm ngẫu nhiên để cập nhật lại vector trọng số tại mỗi bước. Sau khi đi qua hết tất cả các điểm của tập đầu vào, thứ tự các điểm sẽ được xáo trộn và giải thuật lại tiếp tục với từng điểm. Mỗi một lần giải thuật Stochastic Gradient Descent tính toán xong với một điểm được gọi là một *iteration* còn với toàn bộ tập điểm thì gọi là một *epoch*. Cũng bài toán hồi quy tuyến tính ở trên nhưng với giải thuật Stochastic Gradient Descent (hình 2.10), ta có thể thấy số iteration mà giải thuật Stochastic Gradient Descent phải thực hiện trong một epoch là 30. Số phép tính của một lần tính toán là 2.



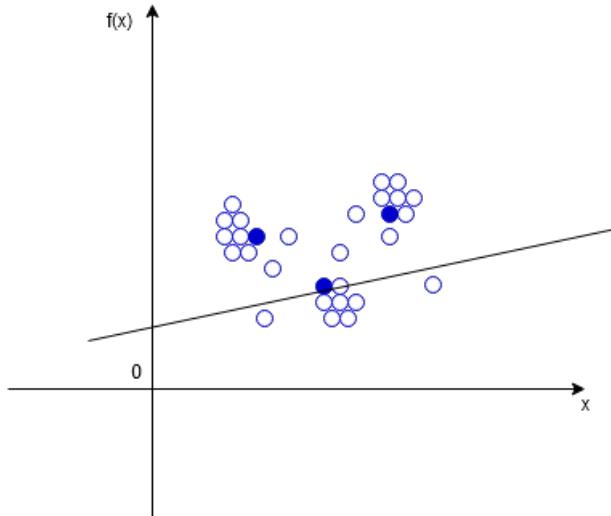
Hình 2.10: Stochastic Gradient Descent với bài toán hồi quy tuyến tính. Một điểm đầu vào được chọn ngẫu nhiên để cập nhật các vector trọng số  $(a, b)$  cho đường hồi quy tại mỗi iteration, với  $a$  là độ dốc và  $b$  độ sai lệch.

Do gradient của 1 điểm chỉ là xấp xỉ gần đúng của trung bình gradient của cả tập điểm nên việc cập nhật tại mỗi iteration sẽ có sai số nhất định, đồng thời các giá trị gradient tính toán được có thể có sự dao động lớn do tập điểm đầu vào thường bị tác động bởi nhiều. Trên thực tế thì kết quả của giải thuật này có mức độ tối ưu khá tốt và hiệu quả tính toán cao. Sau khi đã hoàn thành tính toán trên tập dữ liệu cũ, nếu như có những điểm mới được thêm vào thì ta chỉ cần chạy giải thuật với các điểm mới mà không cần phải chạy lại giải thuật với toàn bộ các điểm như Batch Gradient Descent.

## 3. Mini-batch Gradient Descent

Mini-batch Gradient Descent là sự kết hợp của Batch Gradient Descent và Stochastic Gradient Descent. Một mini-batch sẽ có  $n$  điểm với  $1 < n \leq N$ ,  $N$  là tổng số điểm của tập dữ liệu đầu vào. Việc chia tập điểm ban đầu thành các batch sẽ được thực hiện một cách ngẫu nhiên. Mỗi một lần giải thuật xử lý xong một batch sẽ là một iteration và sau khi tất cả các batch được xử lý thì sẽ là một epoch. Như vậy  $no\_batch = \frac{N}{n}$ . Phương pháp này cho kết quả gần với Batch Gradient Descent nhưng không dùng nhiều tài

nguyên tính toán như Batch Gradient Descent và không cần phải lặp lại nhiều lần như Stochastic Gradient Descent.



Hình 2.11: Mini-batch Gradient Descent với bài toán hồi quy tuyến tính. Một batch sẽ gồm ba điểm đầu vào được chọn ngẫu nhiên để cập nhật các vector trọng số  $(a, b)$  cho đường hồi quy tại mỗi iteration, với  $a$  là độ dốc và  $b$  độ sai lệch. Một epoch sẽ gồm mười batch.

### 2.3.2 Gradient Descent cho hàm đa biến

Việc áp dụng giải thuật Gradient Descent lên hàm đa biến là một sự mở rộng của ví dụ hàm đơn biến ở trên. Hình 2.12 miêu tả mặt phẳng của hàm măt măt trong trường hợp hàm đa biến và quá trình Gradient Descent trên mặt phẳng này. Cho hàm số  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $n \in \mathbb{N}^*$ , ta cần tìm cực tiểu cho  $f(X)$  với  $X = (x_0 \dots x_{n-1})$ ,  $n \in \mathbb{N}^*$  từ một điểm khởi đầu  $X_0$  bằng giải thuật Gradient Descent. Công thức để tính toán cho mỗi bước là:

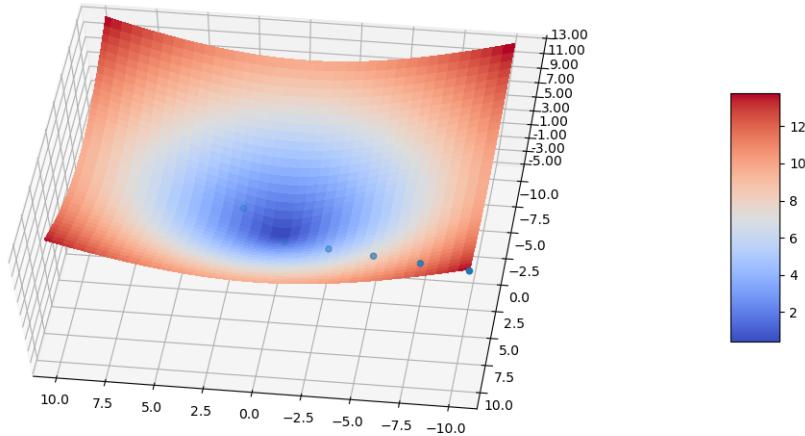
$$X_{k+1} = X_k - \mu \nabla_X f(X_k). \quad (2.5)$$

Phương pháp Gradient Descent thường được dùng để cập nhật trọng số cho bài toán hàm măt măt đa biến là *Mini-batch Gradient Descent*.

### 2.3.3 Điều kiện dừng của giải thuật

Ta đã biết các giải thuật Gradient Descent sẽ cần phải thực hiện rất nhiều vòng lặp tính toán để có thể hội tụ. Tuy nhiên rất khó để nói được khi nào có thể dừng được giải thuật. Trong thực tế có nhiều cách khác nhau được dùng để chọn số bước tính toán:

- Chọn một số lượng vòng lặp nhất định dựa vào một số tiêu chí như số lượng dữ liệu đầu vào. Cách làm này có thể cho kết quả không đủ tốt, có thể nghiệm tối ưu nằm ở các bước trước hoặc sau điểm kết thúc.



Hình 2.12: Đồ thị mặt phẳng hàm măt măt và Gradient Descent cho hàm nhiều biến.

2. Kiểm tra sự thay đổi của hàm măt măt giữa hai lần cập nhật liên tiếp, nếu sự sai lệch đạt tới ngưỡng đủ nhỏ thì ngưng giải thuật. Tuy nhiên nếu trên đồ thị của hàm măt măt có một vùng bằng phẳng nhưng không phải là cực tiểu thì giải thuật sẽ dừng tại điểm này mà không đạt được cực tiểu.
3. Kiểm tra sự thay đổi của gradient giữa hai lần cập nhật liên tiếp, nếu sự sai lệch đạt tới ngưỡng đủ nhỏ thì ngưng giải thuật. Nhược điểm của phương pháp này là việc tính gradient của các hàm phức tạp khó có thể thực hiện được.
4. Kiểm tra kết quả của giải thuật để ngừng việc lặp. Việc này cần người thực hiện việc huấn luyện mô hình phải thường xuyên kiểm tra các tham số hiệu năng của giải thuật lên một tập dữ liệu kiểm tra - *validation set* để xem tại thời điểm nào giải thuật có hiệu năng tốt nhất.

Với một mô hình mạng neuron gồm nhiều lớp ẩn hàm măt măt  $J(\mathbf{W}, \mathbf{b}, \mathbf{X}, \mathbf{Y})$  sẽ phụ thuộc vào tập các ma trận trọng số  $\mathbf{W}$  và tập các vector bias của mỗi lớp  $\mathbf{b}$ . Việc tính gradient của hàm măt măt phụ thuộc vào việc tính các đạo hàm riêng  $\frac{\partial J}{\partial \mathbf{W}^{(k)}}; \frac{\partial J}{\partial \mathbf{b}^{(k)}}, \forall k = 1, 2, \dots, N$ . Với  $N$  là số điểm trong tập điểm đầu vào. Ta nhận thấy để tìm các đạo hàm riêng của  $J$  với  $\mathbf{W}$  và  $\mathbf{b}$  trong trường hợp này là rất khó vì phương trình của  $J$  không phụ thuộc trực tiếp vào  $\mathbf{W}$  và  $\mathbf{b}$ . Để có thể hiện thực các giải thuật thuộc họ Gradient Descent thì phương pháp thường được sử dụng là *backpropagation*.

## 2.4 Sử dụng backpropagation để giải quyết vấn đề cập nhật trọng số trong mạng neuron

Thay vì cập nhật tất cả trọng số cùng một lúc, backpropagation[8, p.220-226] sẽ cập nhật các trọng số theo chiều từ layer cuối cùng đến layer đầu tiên. Đầu tiên giải thuật sẽ tính đạo hàm của hàm mất mát theo ma trận trọng số của lớp cuối cùng.

$$\begin{aligned}\frac{\partial J}{\partial w_{ij}^{(N)}} &= \frac{\partial J}{\partial z_j^{(N)}} \cdot \frac{\partial z_j^{(N)}}{\partial w_{ij}^{(N)}} \\ &= e_j^{(N)} \frac{\partial (w_{ij}^{(N)T} a^{(N-1)} + b_j^{(N)})}{\partial w_{ij}^{(N)}} \\ &= e_j^{(N)} a_i^{(N-1)}\end{aligned}$$

Với  $e_j^{(N)} = \frac{\partial J}{\partial z_j^{(N)}}$  có thể tính được tương đối dễ dàng. Tương tự ta có đạo hàm riêng của  $J$  với bias ở lớp cuối cùng.

$$\begin{aligned}\frac{\partial J}{\partial b_j^{(N)}} &= \frac{\partial J}{\partial z_j^{(N)}} \cdot \frac{\partial z_j^{(N)}}{\partial b_j^{(N)}} \\ &= e_j^{(N)}\end{aligned}$$

Các công thức trên cũng đúng với một lớp bất kỳ trong mạng neuron. Ta lấy mô hình hai lớp liên tiếp của một mạng neuron ở hình 2.7 để đưa ra công thức tổng quát như sau:

$$\begin{aligned}\frac{\partial J}{\partial w_{ij}^{(k)}} &= \frac{\partial J}{\partial z_j^{(k)}} \cdot \frac{\partial z_j^{(k)}}{\partial w_{ij}^{(k)}} \\ &= e_j^{(k)} \frac{\partial (w_{ij}^{(k)T} a^{(k-1)} + b_j^{(k)})}{\partial w_{ij}^{(N)}} \\ &= e_j^{(k)} a_i^{(k-1)} \\ \frac{\partial J}{\partial b_j^{(k)}} &= \frac{\partial J}{\partial z_j^{(k)}} \cdot \frac{\partial z_j^{(k)}}{\partial b_j^{(k)}} \\ &= e_j^{(k)}\end{aligned}$$

Ta sẽ tính  $e_j^{(k)}$  như sau:

$$\begin{aligned} e_j^{(k)} &= \frac{\partial J}{\partial z_j^{(k)}} = \frac{\partial J}{\partial a_j^{(k)}} \cdot \frac{\partial a_j^{(k)}}{\partial z_j^{(k)}} \\ &= \left( \sum_{l=1}^{d^{(k+1)}} \frac{\partial J}{\partial z_l^{k+1}} \cdot \frac{\partial z_l^{(k+1)}}{\partial a_j^{(k)}} \right) f^{(k)'}(z_j^{(k)}) \\ &= \left( \sum_{l=1}^{d^{(k+1)}} e_l^{(k+1)} \cdot w_{jl}^{(k+1)} \right) f^{(k)'}(z_j^{(k)}) \end{aligned}$$

Ta có  $f : \mathbb{R} \rightarrow [0, 1]$  là hàm kích (activation function) hay còn gọi là hàm bao tại một node trong mạng neuron,  $a_j^k = f(z_j^k)$ , do đó ta có đạo hàm riêng của  $a_j^k$  theo  $z_j^k$  chính là đạo hàm của  $f$ . Ngoài ra do  $a_j^k$  trực tiếp tham gia vào việc tính các  $z_l^{k+1}, l = 1, 2, \dots, d^{(k+1)}$  nên  $\frac{\partial J}{\partial a_j^k}$  có thể tách ra thành tổng của tích các đạo hàm riêng như dòng thứ hai. Tương tự như vậy ta có thể tính

$$\frac{\partial J}{\partial b_j^{(k)}} = e_j^{(k)} \quad (2.6)$$

Việc tính  $e_j^k$  sẽ phụ thuộc vào kết quả của  $e_j^{k+1}$  do đó phương pháp này được gọi là backpropagation. Các bước để thực hiện giải thuật backpropagation cho một mạng neuron nhân tạo gồm:

1. Feedforward: Với mỗi giá trị đầu vào của  $x$ , tính giá trị đầu ra của mạng neuron, đồng thời lưu lại các kết quả  $\mathbf{a}^{(k)}$  tại mỗi lớp.
2. Với mỗi node thứ  $j$  ở lớp ngoài cùng tính

$$e_j^{(N)} = \frac{\partial J}{\partial z_j^{(N)}} \quad (2.7)$$

3. Từ đó suy ra:

$$\begin{aligned} \frac{\partial J}{\partial w_{ij}^{(N)}} &= a_i^{(N-1)} e_j^{(N)} \\ \frac{\partial J}{\partial b_j^{(N)}} &= e_j^{(N)} \end{aligned}$$

4. Với  $k = N - 1, N - 2, \dots, 1$  tìm  $e_j^{(k)}$

$$e_j^{(k)} = \left( \sum_{l=1}^{d^{(k+1)}} e_l^{(k+1)} \cdot w_{jl}^{(k+1)} \right) f^{(k)'}(z_j^{(k)}) \quad (2.8)$$

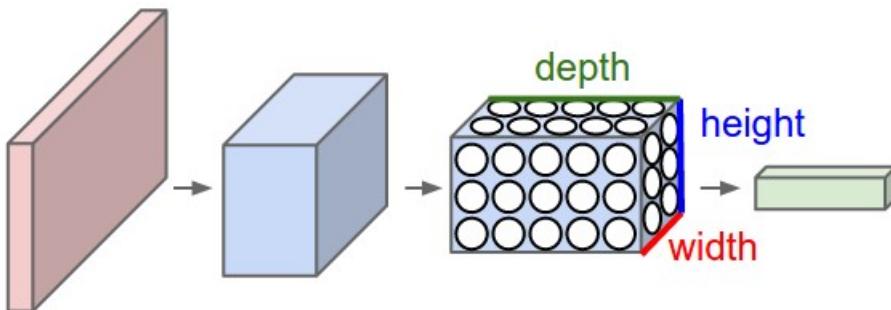
5. Cập nhật đạo hàm cho từng trọng số và bias:

$$\begin{aligned} \frac{\partial J}{\partial w_{ij}^{(k)}} &= a_i^{(k-1)} e_j^{(k)} \\ \frac{\partial J}{\partial b_j^{(k)}} &= e_j^{(k)} \end{aligned}$$

## 2.5 Mạng neuron tích chập

Mạng neuron tích chập[9] (tiếng Anh: Convolutional Neural Network - CNN) là một loại mạng neuron dùng riêng cho các bài toán về hình ảnh. Bên trong mạng neuron tích chập vẫn là các neuron có các trọng số và bias có thể cập nhật được để học các đặc trưng của hình ảnh.

Các lớp của mạng neuron tích chập được bố trí theo ba chiều: chiều rộng (tiếng Anh: width), chiều cao (tiếng Anh: height), chiều sâu (tiếng Anh: depth). Chiều sâu ở đây muốn nói tới chiều sâu của miền các neuron kích hoạt (tiếng Anh: activation volume) chứ không phải là chiều sâu của cả mạng neuron. Các neuron ở lớp sau sẽ chỉ được kết nối với một phần nhỏ các neuron ở lớp trước chứ không phải là toàn bộ như trong các mạng neuron thông thường. Ta lấy ví dụ mạng CIFAR-10 (hình 2.13), miền các neuron kích hoạt ở mạng neuron này có kích thước các chiều là  $32 \times 32 \times 3$  (*rộng*  $\times$  *cao*  $\times$  *sâu*). Lớp cuối cùng của CIFAR-10 sẽ có kích thước các chiều là  $1 \times 10 \times 10$  ứng với vector điểm cho các nhãn cần được phân loại (tiếng Anh: class scores). Một mạng neuron tích chập

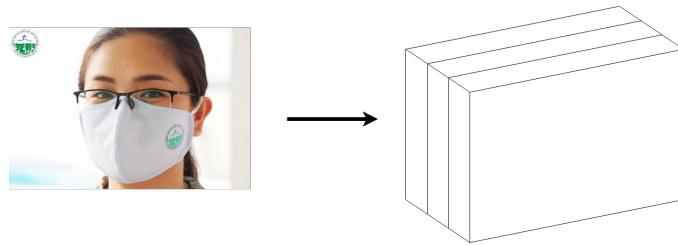


Hình 2.13: Mô hình mạng neuron tích chập đơn giản. Lớp nhận hình ảnh vào màu đỏ là một lớp có cấu trúc ba chiều với chiều rộng và chiều cao là chiều rộng và chiều cao của hình ảnh đầu vào, chiều sâu bằng ba ứng với ba kênh màu đỏ, xanh lá và xanh dương. Các lớp của mạng neuron tích chập sẽ chuyển đổi một nhóm các ma trận thành một nhóm các ma trận khác. Lớp ngoài cùng là lớp phân loại, có kích thước các chiều tương ứng với một vector.

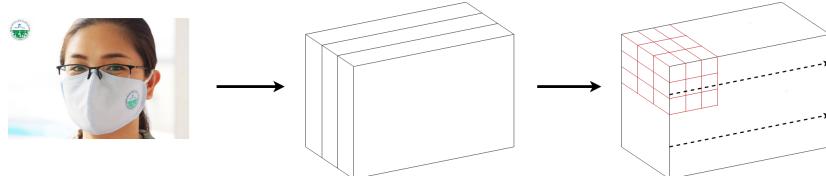
thông thường sẽ được cấu tạo từ ba loại lớp neuron[10, p.113:123]: lớp tích chập (tiếng Anh: convolutional layer), lớp pooling (tiếng Anh: pooling layer) và lớp đầy đủ kết nối (tiếng Anh: fully-connected layer).

### 2.5.1 Lớp tích chập

Trong lớp này đầu vào lớp đầu tiên sẽ là một ảnh màu có ba kênh màu: đỏ, xanh lá, xanh dương (hình 2.14). Đầu ra của các lớp trước sẽ là đầu vào của các lớp sau. Các tensor trong mạng tích chập được gọi là các tensor. Sau đó một bộ lọc có kích thước  $m \times n \times 3$  (tiếng Anh: kernel) sẽ được trượt qua tensor của ảnh đầu vào. Ở mỗi kênh màu, lớp tương ứng của kernel sẽ hoạt động như một cửa sổ trượt (tiếng Anh: sliding window). Nhắc lại một chút về phép toán của cửa sổ trượt trên ảnh trắng đen. Giả sử ta có một cửa sổ trượt có kích thước  $3 \times 3$  đang quét qua một hình trắng đen (hình 2.16), tại vị trí như trên hình việc tính toán



Hình 2.14: Hình ảnh đầu vào gồm ba kênh màu được mô hình hóa thành tensor với chiều cao và chiều rộng là chiều cao và chiều rộng của ảnh, chiều sâu là ba.

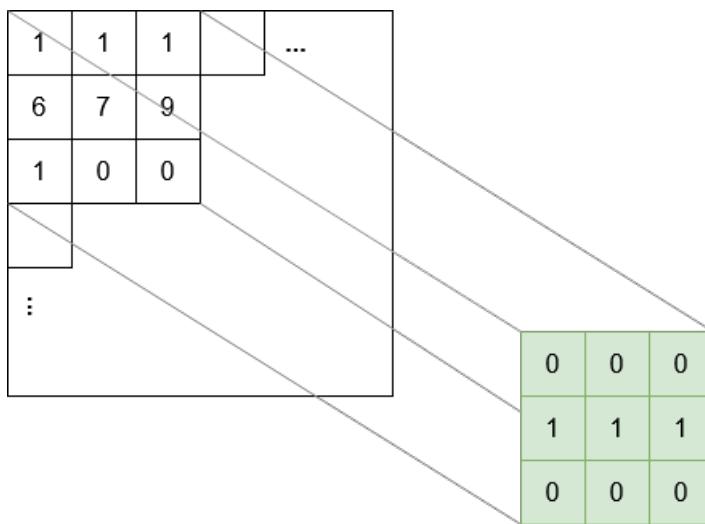


Hình 2.15: Hình ảnh sau khi được đưa vào và chuyển đổi thành dữ liệu ba chiều sẽ được đưa vào lớp convolution đầu tiên. Một kernel có kích thước  $3 \times 3 \times 3$  (góc trên bên trái của mô hình ngoài cùng bên phải) được trượt qua hình đầu vào.

giá trị đầu ra được thực hiện như sau

$$1 \times 0 + 1 \times 0 + 1 \times 0 + 6 \times 1 + 7 \times 1 + 9 \times 1 + 1 \times 0 + 0 \times 0 + 0 \times 0 = 22 \quad (2.9)$$

Ngoài ra, ta còn hai khái niệm cần nhắc tới là stride và padding.



Hình 2.16: Ví dụ về phép toán cửa sổ trượt với kích thước  $3 \times 3$ .

- Với stride bằng một thì cửa sổ trượt sẽ di chuyển tuần tự qua tất cả các ô của ma trận. Tổng quát với  $stride = k$  thì các điểm ảnh được cửa sổ trượt đi qua của một ma trận có kích thước  $m \times n$  sẽ là  $x_{1+i \times k, 1+j \times k}$  với  $i, j \in \mathbb{N}; 1 + i \times k \leq m; 1 + j \times k \leq n$ .
- Đối với các điểm ảnh ở gần biên, nếu như trong vùng cửa sổ không có những chỗ không tồn tại giá trị điểm ảnh thì các phương pháp chèn giá trị (tiếng

Anh: padding) sẽ được sử dụng để thay làm các giá trị tính toán. Một trong các cách padding phổ biến là dùng các giá trị bằng không (tiếng Anh: zero padding).

0	0	0	0	0
0	2	3	-2	0
0	9	1	0	0
0	1	2	3	0
0	0	0	0	0

0	0	0	0	0	0	0
0	0	0	0	0	0	0
0	0	2	3	-2	0	0
0	0	9	1	0	0	0
0	0	1	2	3	0	0
0	0	0	0	0	0	0
0	0	0	0	0	0	0

Hình 2.17: Bên trái, ma trận  $3 \times 3$  được zero padding với  $padding = 1$ . Bên phải, ma trận  $3 \times 3$  được zero padding với  $padding = 2$

Như vậy, nếu đầu vào của phép tính tích chập là ma trận  $X$  có kích thước  $m \times n$  với cửa sổ trượt có kích thước  $k \times k$ ,  $stride = s$ ,  $padding = p$  thì đầu ra sẽ là một ma trận  $Y$  có kích thước  $(\frac{m-k+2p}{s} + 1) \times (\frac{n-k+2p}{s} + 1)$

Việc tính toán tại mỗi kênh màu của hình khi kernel đi qua cũng gần tương tự với cửa sổ trượt. Kết quả phép toán của ba kênh màu và một bias sẽ được cộng lại và đưa vào ma trận kết quả. Giả sử ta có một kernel có kích thước  $3 \times 3 \times 3$  như hình 2.18. Dữ liệu một ảnh đầu vào gồm ba kênh màu, khi đi qua lớp tích

-1	0	1
0	1	-1
1	-1	-1

0	0	0
1	1	1
0	0	0

0	1	0
0	1	0
0	1	0

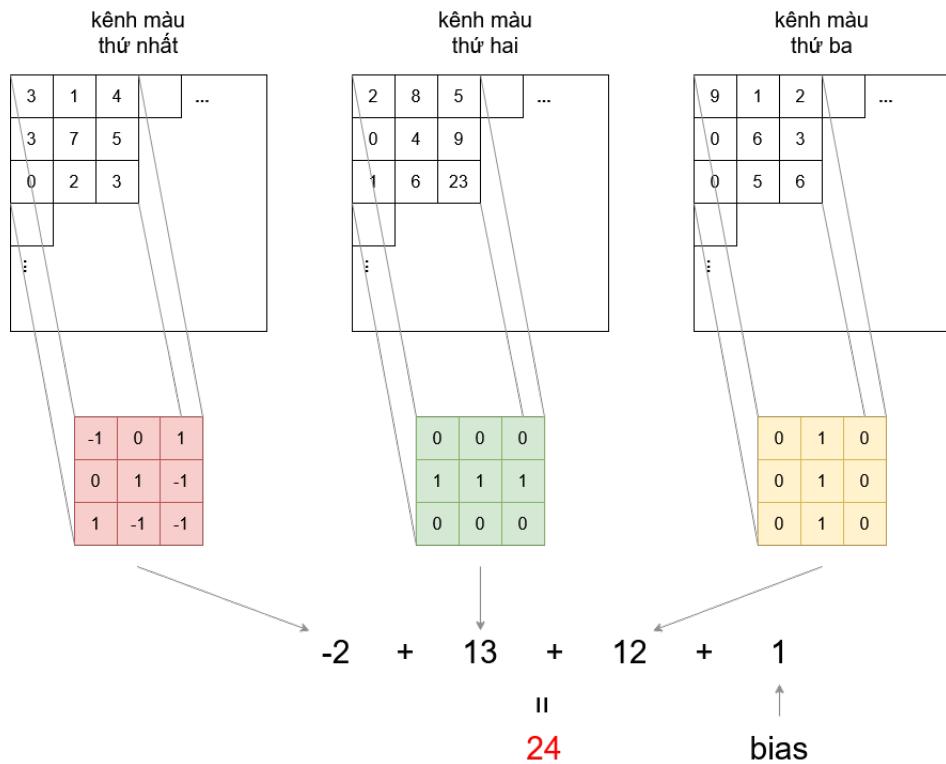
kênh kernel  
thứ nhất

kênh kernel  
thứ hai

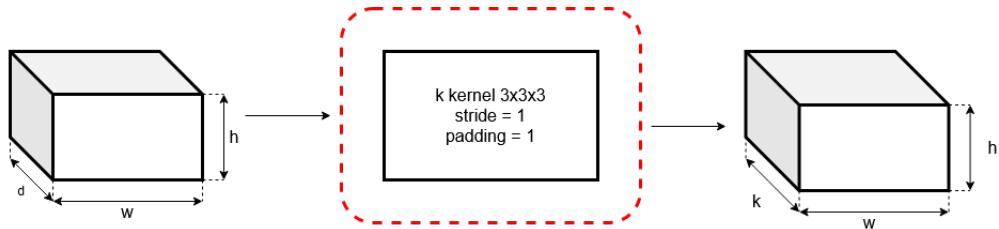
kênh kernel  
thứ ba

Hình 2.18: Ví dụ về một kernel có kích thước  $3 \times 3 \times 3$ .

chập đầu tiên sẽ được tính toán như hình 2.19 Sau khi kernel đã quét qua hết các điểm ảnh mong muốn thì kết quả nhận được sẽ là một ma trận. Mỗi một kernel khác nhau sẽ trích xuất ra được một đặc trưng khác nhau của ảnh. Do đó một lớp tích chập sẽ có nhiều kernel để lấy các đặc trưng khác nhau. Lúc này đầu ra sẽ là một tensor gồm nhiều ma trận. Nếu như có  $k$  kernel được dùng tại một lớp tích chập thì đầu ra sẽ có chiều sâu bằng  $k$ , chiều rộng và chiều cao sẽ bằng chiều rộng và chiều cao của ảnh đầu vào. Đầu ra của lớp tích chập trước sẽ là đầu vào của lớp tích chập sau. Tổng quát hóa, với một lớp tích chập với  $K$  kernel có kích thước  $N \times N \times D$  (với  $D$  là chiều sâu của đầu vào và là số lẻ),  $stride = S$ ,



Hình 2.19: Ví dụ về phép toán của một kernel lên một vị trí của ảnh trong lớp tích chập.



Hình 2.20: Một lớp tích chập có  $k$  kernel với kích thước  $3 \times 3 \times 3$ ,  $stride = 1$ ,  $padding = 1$ . Đầu vào là một tensor có kích thước  $h \times w \times d$  đầu ra của phép tích chập lên tensor này khi khôi tích chập có các thông số ở trên là một tensor có kích thước  $h \times w \times k$

$padding = P$ . Đầu vào là một tensor có kích thước  $H \times W \times D$  thì kích thước của tensor đầu ra sẽ là  $(\frac{H-F+2P}{S} + 1) \times (\frac{W-F+2P}{S} + 1) \times K$

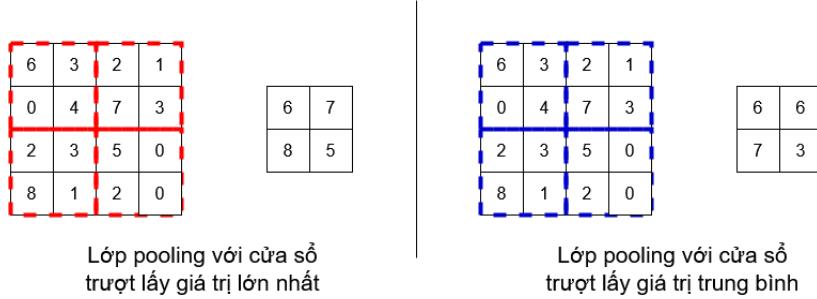
Dầu ra của lớp tích chập sẽ đi qua hàm kích hoạt trước khi được đưa vào lớp tích chập tiếp theo. Mỗi kernel với kích thước  $N \times N \times D$  sẽ có một hệ số bias tương ứng với tổng số các tham số của một kernel là  $N \times N \times D + 1$ , với  $K$  kernel thì số tham số sẽ là  $K \times (N \times N \times D + 1)$ .

### 2.5.2 Lớp pooling

Việc tính toán với toàn bộ dữ liệu đầu vào của ảnh có độ phân giải lớn và kích thước lớn trên mạng neuron tích chập thường không hiệu quả về mặt tính toán do sẽ có nhiều điểm ảnh miêu tả cùng một đặc trưng. Do đó lớp pooling được dùng ở giữa các lớp tích chập để giảm kích thước của các tensor nhưng vẫn

không làm mất đi các đặc trưng của dữ liệu.

Cho một lớp pooling có kích thước cửa sổ trượt là  $N \times N$ , đầu vào là một tensor có kích thước  $H \times W \times D$ . Ta chia tensor này thành  $D$  ma trận  $H \times W$ . Với mỗi ma trận ta lần lượt trượt cửa sổ trượt của lớp pooling lên từng điểm ảnh. Trong vùng dữ liệu của cửa sổ trượt ta sẽ tìm giá trị lớn nhất hoặc trung bình của các giá trị để đưa vào ma trận mới. Một số mô hình mạng neuron tích chập



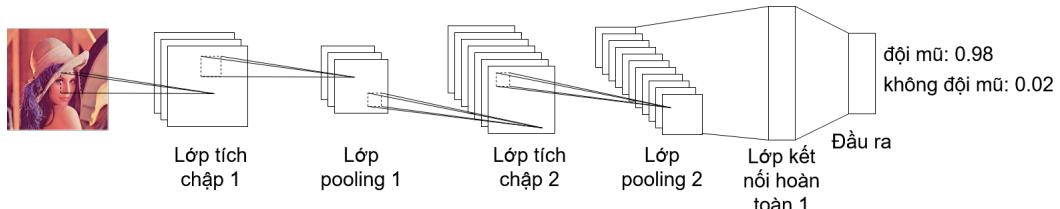
Hình 2.21: Bên trái, lớp pooling với cửa sổ trượt lấy giá trị lớn nhất với kích thước cửa sổ  $2 \times 2$ ,  $stride = 1$ ,  $padding = 0$ . Bên phải, lớp pooling với cửa sổ trượt lấy giá trị trung bình với kích thước cửa sổ  $2 \times 2$ ,  $stride = 2$ ,  $padding = 0$ .

sẽ dùng  $stride > 1$  trong lớp tích chập để làm giảm kích thước dữ liệu thay vì dùng lớp pooling. Ngoài ra, trong thực tế lớp pooling thường được sử dụng với kích thước cửa sổ trượt  $2 \times 2$ ,  $stride = 2$ ,  $padding = 0$ . Chiều cao và chiều rộng của tensor đầu ra sẽ giảm đi một nửa còn chiều sâu vẫn giữ nguyên.

### 2.5.3 Lớp đầy đủ kết nối

Hình ảnh sau khi qua các lớp tích chập và pooling thì đầu ra sẽ là một tensor chứa các đặc trưng mà mô hình trích xuất được. Tensor có kích thước  $H \times W \times D$  tại lớp tích chập cuối cùng sẽ được chuyển thành một vector có chiều dài  $H \times W \times D$ . Sau đó vector này sẽ được đưa vào các lớp đầy đủ kết nối để đưa ra kết quả dự đoán cho ảnh.

Sau cùng ta có thể kết nối các lớp đã nêu ở trên thành một mạng neuron tích chập đơn giản như trong hình 2.22. Ảnh đầu vào  $\rightarrow$  [Lớp tích chập  $\rightarrow$  Lớp pooling]  $\times n \rightarrow$  [Lớp liên kết hoàn toàn]  $\times m \rightarrow$  Đầu ra, với  $m, n \in \mathbb{N}^*$ .



Hình 2.22: Mạng neuron tích chập gồm hai lớp tích chập và pooling, một lớp kết nối đầy đủ.

## 2.6 Mô hình YOLOv3

YOLO - You Only Look Once[11] là một trong những mô hình nhận diện thời gian thực hiện đại nhất và đang được sử dụng cho nhiều bài toán nhận diện, theo dõi khác nhau. Không như những mạng CNN hay R-CNN trước đây, thay vì sử dụng phương pháp dự đoán trên từng miền (tiếng Anh: region proposal method) và cửa sổ trượt (tiếng Anh: sliding window) để phát hiện vật thể trong từng vùng nhỏ trong khung hình và tiến hành phân loại vật thể đó. YOLO sử dụng cả khung hình để nhận diện vật thể, các đặc trưng của vùng nền phía sau (tiếng Anh: background) cũng được dùng trong quá trình huấn luyện. Do vậy YOLO có thể nhận diện vật thể một cách nhanh chóng trong một khung hình với độ chính xác cao chỉ với một lần xử lý, đó cũng là lý do vì sao mô hình này được gọi là Bạn Chỉ Cần Nhìn Một Lần (tiếng Anh: You Only Look Once).

### 2.6.1 Unified Detection

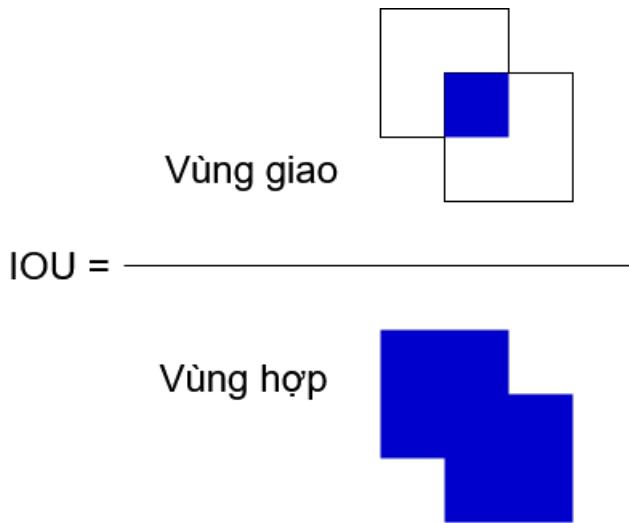
Hình ảnh đầu vào được chia thành một mạng lưới ô vuông (tiếng Anh: grid cell) có kích thước  $S \times S$ . Nếu như tâm của một vật thể nằm ở tâm của một ô thì ô đó sẽ chịu trách nhiệm trong việc nhận diện vật thể đó. Mỗi ô sẽ dự đoán  $B$



Hình 2.23: Hình ảnh được chia thành mạng lưới ô vuông  $S \times S$ .

bounding box và độ tin cậy (tiếng Anh: confidence score) của từng bounding box. Gọi  $Pr(\text{Object})$  là xác suất của vật thể nằm trong một ô với  $Pr(\text{Object}) \in \mathbb{R}, 0 \leq Pr(\text{Object}) \leq 1$ .  $IOU$  - intersection over union là tỉ lệ giữa diện tích miền giao và diện tích miền hợp của bounding box dự đoán được và bounding box được tạo sẵn để huấn luyện (tiếng Anh: ground truth) hình 2.24,  $IOU \in \mathbb{R}, 0 \leq IOU \leq 1$ . Độ tin cậy sẽ được định nghĩa bằng  $Pr(\text{Object}) \times IOU$ , nếu như một ô không chứa vật thể thì  $Pr(\text{Object}) = 0$  suy ra độ tin cậy sẽ bằng không, ngược lại nếu một ô chứa vật thể thì  $Pr(\text{Object}) = 1$ , lúc này độ tin cậy bằng  $IOU$ .

Mỗi một bounding box sẽ có năm tham số cần dự đoán:  $t_x, t_y, t_w, t_h$  và độ tin cậy.  $(t_x, t_y)$  là tọa độ tương đối của tâm bounding box với một ô, nếu gọi offset của một ô trong hình là  $(c_x, c_y)$  thì tọa độ của một bounding box so với hình sẽ là  $(\sigma(t_x) + c_x, \sigma(t_y) + c_y)$ . Nếu chiều dài và chiều rộng của bounding box cho trước là  $(p_w, p_h)$  chiều dài và chiều rộng của bounding box được sự đoán sẽ là

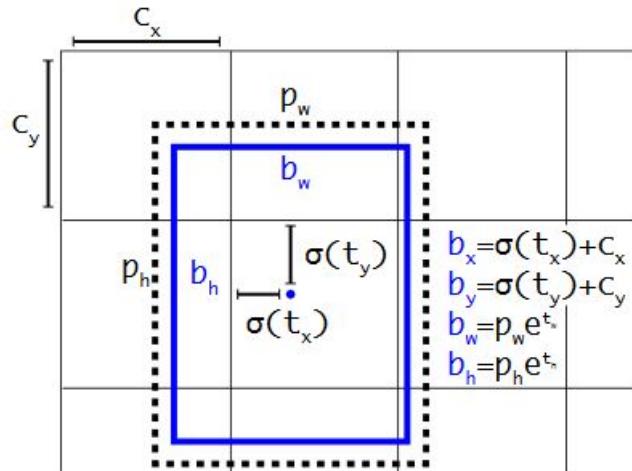


Hình 2.24: Miêu tả việc tính toán IOU.

$$(p_w \times e^{t_w}, p_h \times e^{t_h}).$$

$$\begin{aligned} b_x &= \sigma(t_x) + c_x \\ b_y &= \sigma(t_y) + c_y \\ b_w &= p_w \times e^{t_w} \\ b_h &= p_h \times e^{t_h} \end{aligned}$$

Trong quá trình huấn luyện, hàm mất mát tổng bình phương sai số được sử dụng



Hình 2.25: Mô hình dự đoán bounding box của YOLO.

cho các tọa độ của bounding box. Với một dự đoán  $t_*$  có ground truth là  $\hat{t}_*$  thì gradient sẽ là hiệu giữa ground truth và kết quả dự đoán được  $\hat{t}_* - t_*$ .

YOLOv3[12] sử dụng hàm hồi quy logistic để dự đoán xem một bounding box có chứa vật thể hay không. Nếu như bounding box dự đoán được giao với ground truth nhiều hơn các bounding box trước đó thì kết quả là 1. Nếu như một bounding box dự đoán được không phải là trường hợp có diện tích giao lớn nhất với ground truth nhưng vẫn có độ tin cậy lớn hơn một ngưỡng xác quyết thì dự đoán với bounding box này sẽ bị bỏ qua. Ngưỡng xác quyết được dùng là 0.5.

Nếu như một bounding box không được đặt vào một ground truth thì sẽ không có các dự đoán về tọa độ và class mà chỉ có dự đoán về sự tồn tại của vật thể.

Dộ tin cậy chính là  $IOU$  giữa bounding box dự đoán được và bounding box được tạo sẵn. Đối với những ô được dự đoán có vật thể, mô hình sẽ dự đoán thêm  $C$  xác suất của các class mà vật thể đó thuộc về  $Pr(Class_i|Object)$  với  $Pr(Class_i|Object) \in \mathbb{R}, 0 \leq Pr(Class_i|Object) \leq 1, i = 1, \dots, C$ . Mỗi ô sẽ chỉ có một tập các giá trị  $Pr(Class_i|Object)$  mà không liên quan tới số lượng bounding box  $B$ .

Khi tiến hành dự đoán, YOLO sẽ nhân các xác suất và độ tin cậy lại với nhau để được xác suất của một class trên một bounding box.

$$Pr(Class_i|Object) \times Pr(Object) \times IOU = Pr(Class_i) \times IOU \quad (2.10)$$

Hàm mất mát được sử dụng khi huấn luyện để dự đoán các class là hàm binary cross-entropy nhằm giúp mô hình có thể dự đoán đa lớp trong cùng một ô.

Sau cùng ta có hàm mất mát tổng của YOLOv3

$$\begin{aligned} Loss &= \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbf{1}_{ij}^{obj} \left[ (\hat{t}_{x_{ij}} - t_{x_{ij}})^2 + (\hat{t}_{y_{ij}} - t_{y_{ij}})^2 + (\hat{t}_{w_{ij}} - t_{w_{ij}})^2 + (\hat{t}_{h_{ij}} - t_{h_{ij}})^2 \right] \\ &\quad + \sum_{i=0}^{S^2} \sum_{j=0}^B - [\hat{p}_{o_{ij}} \times \log(p_{o_{ij}}) + (1 - \hat{p}_{o_{ij}}) \times \log(1 - p_{o_{ij}})] \\ &\quad + \sum_{i=0}^{S^2} \mathbf{1}_{ij}^{obj} \sum_{k=1}^C - [\hat{p}_i(c_k) \times \log(p_i(c_k)) + (1 - \hat{p}_i(c_k)) \times \log(1 - p_i(c_k))] \end{aligned}$$

## 2.6.2 Kiến trúc mạng YOLOv3

Các đặc trưng từ ảnh được trích xuất theo ba tỉ lệ khác nhau bằng phương pháp giống như phương pháp được sử dụng trong mạng trích xuất đặc trưng dạng kim tự tháp (tiếng Anh: feature pyramid networks). Đầu ra của miền trích xuất đặc trưng là một tensor ba chiều chứa vị trí bounding box, xác suất tồn tại vật thể, xác suất các class, kích thước của tensor là  $S \times S \times [3 \times (4 + 1 + C)]$ , với  $S \times S$  là số ô mà ảnh được chia thành, 4 là các giá trị dự đoán của bounding box ( $t_x, t_y, t_w, t_h$ ), 1 là giá trị dự đoán sự tồn tại của vật thể trong ô,  $C$  là vector các giá trị dự đoán của các class.

Sau đó các ma trận đặc trưng từ hai lớp trước và upsample lên hai lần. Ngoài ra các ma trận đặc trưng từ các lớp đầu cũng được ghép lại với các lớp sau. Việc này giúp mô hình lấy được nhiều thông tin có ý nghĩa từ các ma trận đặc trưng được upsample và vẫn giữ được được những đặc trưng nhỏ hơn từ các lớp đầu. Sau đó một vài lớp tích chập được sử dụng để kết hợp các ma trận đặc trưng và đưa ra tensor sau cùng chứa các dự đoán có kích thước gấp đôi.

Với tỉ lệ cuối, mô hình như ở trên được lặp đi lặp lại nhiều lần, điều này cho phép các bounding box ở tỉ lệ cuối có thể dùng các giá trị đã được tính toán từ các tỉ lệ trước cũng nhưng các đặc trưng có ý nghĩa.

Ban đầu sẽ có chín bounding box:  $(10 \times 13)$ ,  $(16 \times 30)$ ,  $(33 \times 23)$ ,  $(30 \times 61)$ ,  $(62 \times 45)$ ,  $(59 \times 119)$ ,  $(116 \times 90)$ ,  $(156 \times 198)$ ,  $(373 \times 326)$ . Các bounding box này sẽ được chia vào ba tỉ lệ bằng giải thuật k-means. Các bounding box này sẽ được dùng để dự đoán ở các tỉ lệ tương ứng. Ảnh đầu vào sẽ được downsample với các stride

bằng 32, 16 và 8 cho từng tỉ lệ. Nhờ vậy YOLOv3 có thể dự đoán được các vật thể nhỏ rất tốt.

YOLOv3 sử dụng kiến trúc mạng kết hợp giữa YOLOv2, Darknet-19 và mạng residual. Các lớp tích chập có kích thước  $3 \times 3$ ,  $1 \times 1$  và có thêm các liên kết tắt (tiếng Anh: short cut). Trên hình 2.26 thể hiện kiến trúc Yolov3 có tất cả 53 lớp tích chập được dùng nên kiến trúc này được gọi là Darknet-53. Kiến trúc này cho

Type	Filters	Size	Output
Convolutional	32	$3 \times 3$	$256 \times 256$
Convolutional	64	$3 \times 3 / 2$	$128 \times 128$
1x	32	$1 \times 1$	
	64	$3 \times 3$	
	Residual		$128 \times 128$
Convolutional	128	$3 \times 3 / 2$	$64 \times 64$
2x	64	$1 \times 1$	
	128	$3 \times 3$	
	Residual		$64 \times 64$
Convolutional	256	$3 \times 3 / 2$	$32 \times 32$
8x	128	$1 \times 1$	
	256	$3 \times 3$	
	Residual		$32 \times 32$
Convolutional	512	$3 \times 3 / 2$	$16 \times 16$
8x	256	$1 \times 1$	
	512	$3 \times 3$	
	Residual		$16 \times 16$
Convolutional	1024	$3 \times 3 / 2$	$8 \times 8$
4x	512	$1 \times 1$	
	1024	$3 \times 3$	
	Residual		$8 \times 8$
Avgpool		Global	
Connected		1000	
Softmax			

Hình 2.26: Kiến trúc mạng Darknet-53.

khả năng nhận diện tốt hơn Darknet-19 và hiệu năng cao hơn ResNet-101 hoặc ResNet-152 bảng 2.1.

Backbone	Top-1	Top-5	Bn Ops	BFLOP/s	FPS
Darknet-19	74.1	91.8	7.29	1246	<b>171</b>
ResNet-101	77.1	93.7	19.7	1039	53
ResNet-152	<b>77.6</b>	<b>93.8</b>	29.4	1090	37
Darknet-53	77.2	<b>93.8</b>	18.7	1457	78

Bảng 2.1: So sánh hiệu năng của Darknet-53 với các mạng khác. Accuracy, Bn Ops - billions of operations, BFLOP/s - billion floating point operations per second, và FPS - frames per second.

Chương này đã trình bày các lý thuyết về neuron và mạng neuron nhân tạo, ý nghĩa của hàm mất mát và việc tối ưu hàm mất mát đối với việc học của một

mạng neuron. Cách mà một mạng neuron sử dụng giải thuật Gradient Descent kết hợp với kỹ thuật backpropagation để tối ưu hàm mất mát. Đồng thời trong lý thuyết về mạng neuron tích chập và YOLOv3 ngoài những khái niệm của những phần trước thì các khai niệm mới cũng được đề cập tới để người đọc hiểu hơn về cách mà trí tuệ nhân tạo đang được dùng để giải quyết các bài toán hình ảnh từ đó nắm rõ hơn lý do của việc ứng dụng YOLOv3 ở chương sau.

## Chương 3

# Xây dựng tập dữ liệu, huấn luyện và sử dụng mô hình YOLOv3 cho bài toán nhận diện thiết bị bảo hộ cá nhân

Trong chương này, người đọc sẽ đi qua các giai đoạn khi xây dựng mô hình máy học để giải quyết bài toán trong luận văn. Bắt đầu từ việc xây dựng tập dữ liệu, sau đó các thao tác cần thiết để huấn luyện mô hình YOLOv3 dùng framework darknet. Cuối cùng là cách sử dụng mô hình đã được huấn luyện vào một chương trình cụ thể.

### 3.1 Xây dựng tập dữ liệu cho bài toán nhận diện thiết bị bảo hộ cá nhân

#### 3.1.1 Xác định yêu cầu bài toán

Bài toán đặt ra là nhận diện người trong khung hình có đang đeo các thiết bị bảo hộ cá nhân (tiếng Anh: personal protective equipment) hay không. Các thiết bị bảo hộ cá nhân được chọn để nhận diện là: mũ bảo hộ, áo bảo hộ và khẩu trang.



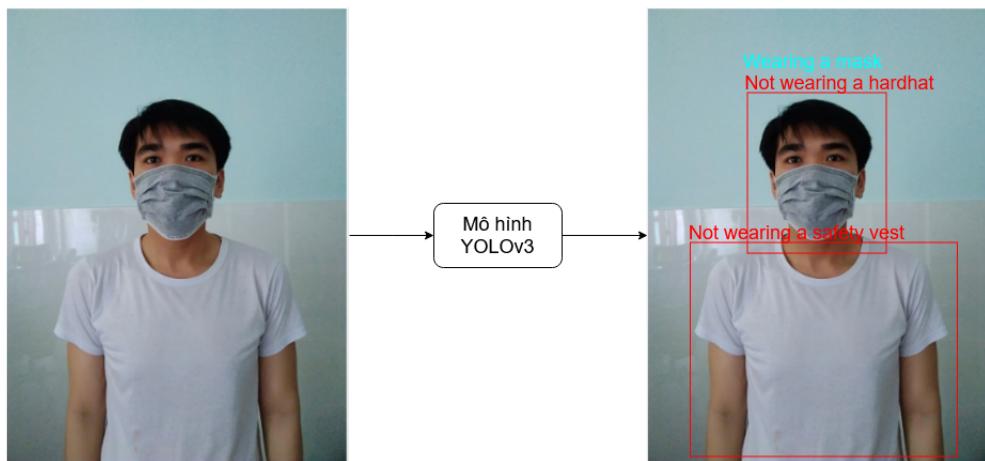
Hình 3.1: (1) Mũ bảo hộ, (2) Áo bảo hộ, (3) Khẩu trang

Mục tiêu đầu ra của hệ thống là có thể xác định được vị trí đầu người và thân người và phân loại việc sử dụng các thiết bị bảo hộ cá nhân đối với các vật

thể đã được phát hiện. Ứng với mỗi thiết bị, vật thể sẽ được phân loại thành hai trạng thái, một là *Wearing - Mặc*, hai là *Not wearing - Không mặc*.

- Wearing a hardhat
- Not wearing a hardhat
- Wearing a safety vest
- Not wearing a safety vest
- Wearing a mask
- Not wearing a mask

Hình 3.2 minh họa đầu vào đầu ra mong muốn của hệ thống.



Hình 3.2: Kết quả nhận dạng mong muốn.

Do vậy tập dữ liệu sẽ được xây dựng với các hình ảnh chứa con người và các nhãn được đánh đúng với mong muốn của đầu ra.

### 3.1.2 Thu thập hình ảnh và dán nhãn

Tập dữ liệu gồm 11586 hình trong đó

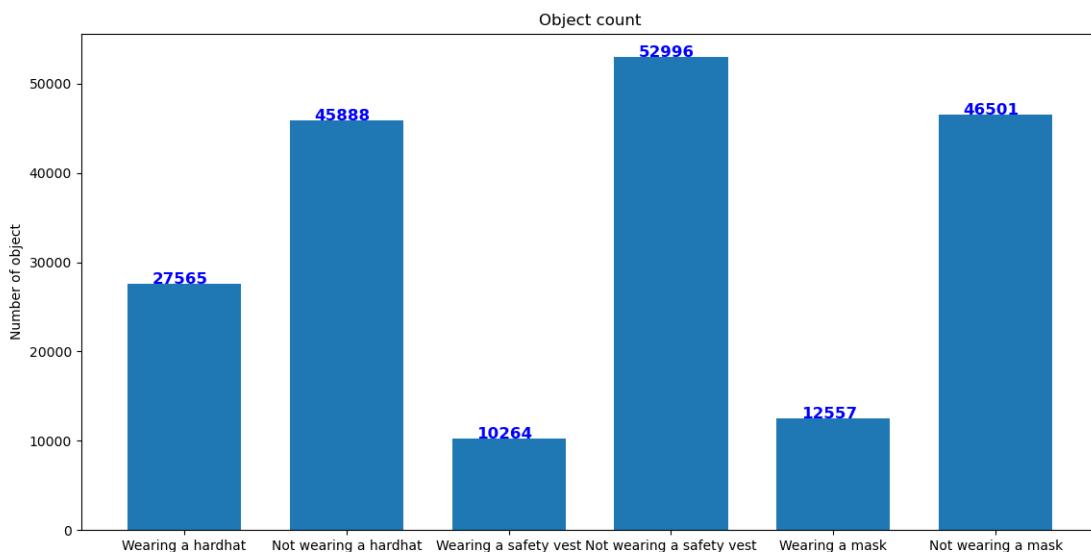
- 3541 hình được lấy từ tập dữ liệu *Hardhat and Safety Vest Image for Object Detection*[13]
- 3174 hình được lấy từ tập dữ liệu *GDUT-HWD*[14]
- 4871 hình được lấy từ công cụ tìm kiếm hình ảnh *Google image*

Các hình được dán nhãn bằng phần mềm *LabelImg*[15]. Mỗi hình sẽ có tương ứng một tệp tin văn bản với đuôi *.txt*. Bên trong tệp tin này là các nhãn được đánh dấu bằng định dạng của YOLO với các thông tin gồm *object class id* - đây là id tương ứng với thứ tự của một nhãn trong danh sách các nhãn, *x* và *y* là tọa độ tương đối của bounding box được đánh dấu với hình, *w* và *h* là chiều rộng và chiều cao tương đối của bounding box được đánh dấu với hình, hình 3.3.



3 0.590820 0.732087 0.404297 0.448598  
 1 0.649414 0.323988 0.306641 0.560748  
 4 0.649414 0.323988 0.306641 0.560748

Hình 3.3: Định dạng nhãn của YOLO.



Hình 3.4: Thống kê số lượng vật thể ứng với từng class. Wearing a hardhat: 27565, Not wearing a hardhat: 45888, Wearing a safety vest: 10264, Not wearing a safety vest: 52996, Wearing a mask: 12557, Not wearing a mask: 46501.

Tập dữ liệu này có tổng cộng **195771** vật thể được dán nhãn với thống kê số vật thể của từng class được thể hiện trong hình 3.4.

Việc chênh lệch lớn về số lượng các bounding box giữa các class cụ thể là các class *Not wearing* có số lượng lớn hơn rất nhiều so với các class *Wearing* tương ứng sẽ giúp bộ nhận dạng nhạy hơn với các trường hợp vi phạm trang phục bảo vệ lao động. Tuy có sự chênh lệch lớn nhưng số lượng các bounding box của mỗi class là đủ lớn để mô hình có thể học được các đặc trưng cần thiết để có thể phân loại class tốt cho một bounding box.

### 3.2 Huấn luyện mạng YOLOv3 sử dụng framework Darknet với tập dữ liệu riêng

Darknet[16] là một framework được xây dựng bởi Joseph Redmon cũng là cha đẻ của YOLO, framework này được viết bằng C/C++ và được dùng để huấn luyện mô hình YOLOv3 với tập dữ liệu riêng cho từng vấn đề. Kiến trúc của Darknet đã được đề cập ở phần lý thuyết và sẽ không được nhắc lại ở chương này.

Mô hình YOLOv3 trong luận văn này được huấn luyện trên *GoogleColab*, về bản chất môi trường trên *GoogleColab* là môi trường máy ảo chạy Linux với các thông số tại thời điểm thực hiện luận văn:

- Hệ điều hành: Ubuntu 18.04.3 LTS
- Chip xử lý: Intel 2-core Xeon 2.2GHz
- RAM: 13Gb
- HDD: 33Gb
- GPU: Tesla K80 with 12GB memory

Để có thể huấn luyện được mô hình YOLOv3 cho bộ dữ liệu riêng, ta cần thực hiện một số bước.

1. Tải framework Darknet từ github repository của AlexeyAB.

<https://github.com/AlexeyAB/darknet>

Sau đó ta chọn Clone → Download ZIP và tiến hành tải thư mục về, sau khi tải xong ta tiến hành giải nén vào một thư mục mà ta tạo sẵn.

2. Ta chép tệp tin *yolov3.cfg* trong thư mục *cfg* ra thư mục làm việc *darknet* và chỉnh sửa như sau.

- Đầu tiên ta sẽ sửa các giá trị *batch* là số hình trong một mini-batch mà ta muốn dùng để huấn luyện, *subdivision* là thông số để chia nhỏ một mini-batch để đảm bảo mô hình có thể chạy trên các tài nguyên GPU khác nhau, do tập dữ liệu gồm nhiều hình có kích thước khác nhau nên trong quá trình huấn luyện nếu để *subdivision* nhỏ thì rất dễ gặp lỗi *out of memory* do đó sau khi thử nhiều giá trị khác nhau như 16, 32, 64 thì 64 cho phép việc training diễn ra tối nhất. Đổi lại thì thời gian training sẽ lâu hơn do không thể đưa nhiều hình vào cùng một lúc để huấn luyện.
- *width* và *height* là chiều rộng và chiều cao của ảnh đầu vào, các ảnh có kích thước khác nhau sẽ được resize lại kích thước này trước khi được đưa vào để huấn luyện. Việc lựa chọn giá trị *width* và *height* sẽ ảnh hưởng tới việc học của mô hình, nếu như tài nguyên GPU là lớn thì các giá trị của *width* và *height* nên chọn càng lớn càng tốt, tuy nhiên trong bài toán này để đảm bảo hình ảnh sau khi resize không mất quá nhiều thông tin, đồng thời đảm bảo việc huấn luyện có thể thực hiện được trên tài nguyên GPU được cung cấp nên *width* và *height* được chọn là 608.

- Việc lựa chọn *max\_batches* là tổng số batch mà mô hình sẽ chạy qua, đây còn được gọi là số *iteration*, ta có thể chọn *max\_batches* rất lớn và dựa vào *mAP* hoặc *average loss* để dừng giải thuật, nhưng sau khi huấn luyện mô hình một vài lần cho thấy *max\_batches* nên xấp xỉ lớn hơn số class nhân 2000 nhưng không nhỏ hơn số lượng hình trong tập dữ liệu huấn luyện. *steps* sẽ có giá trị lần lượt bằng 80% và 90% của *max\_batches*.

```
# [net]
# Testing
# batch=1
# subdivisions=1
# Training
batch=64
subdivisions=64
width=608
height=608
channels=3
momentum=0.9
decay=0.0005
angle=0
saturation = 1.5
exposure = 1.5
hue=.1

learning_rate=0.001
burn_in=1000
max_batches = 22000
policy=steps
steps=17600,19800
scales=.1,.1
```

Sau đó tại các dòng 610, 696 và 783 ta sẽ thay số *classes* bằng sáu, chính là số class của bài toán. Đồng thời ta sẽ sửa số *filters* của lớp convolution ngay phía trên theo công thức  $3 \times (5 + C)$  với  $C$  là số class, 3 là số scale mà mô hình sẽ dự đoán, 5 gồm 4 tham số tọa độ của bounding box và 1 tham số dự đoán sự tồn tại của vật thể trong bounding box đó, khi  $C = 6$  ta có *filters* = 33.

```
[convolutional]
size=1
stride=1
pad=1
filters=33
activation=linear

[yolo]
mask = 0, 1, 2
anchors = 10, 13, 16, 30, 33, 23, 30, 61, 62, 45, 59, 119, 116, 90, 156
, 198, 373, 326
classes=6
num=9
jitter=.3
ignore_thresh = .7
truth_thresh = 1
random=1
```

- Sửa các thông số ở đầu của tệp *Makefile* như sau. OpenCV và GPU sẽ được sử dụng trong quá trình huấn luyện và dự đoán nên hai giá trị này sẽ được cài đặt là 1.

```
GPU=1
CUDNN=0
CUDNN_HALF=0
OPENCV=1
AVX=0
OPENMP=0
LIBSO=0
ZED_CAMERA=0 # ZED SDK 3.0 and above
ZED_CAMERA_v2_8=0 # ZED SDK 2.X
```

- Tạo tệp có tên *obj.names* chứa tên các class.

```
Wearing a hardhat
Not wearing a hardhat
Wearing a safety vest
Not wearing a safety vest
Wearing a mask
Not wearing a mask
```

- Sao chép tệp dữ liệu gồm hình ảnh và tệp tin dán nhãn vào đường dẫn *./data/objects*
- Tạo hai tệp text, *train.txt* và *val.txt* chứa đường dẫn đến các hình ảnh. *train.txt* sẽ được dùng để huấn luyện còn *val.txt* sẽ được dùng để validate mô hình trong quá trình huấn luyện. Việc chia tập dữ liệu được thực hiện ngẫu nhiên. Có **900** hình được dùng để validate và **10686** hình được dùng để huấn luyện. Việc chia này được thực hiện bằng một chương trình Python.

```

import os
import glob
import cv2
import random

basenames =
    [os.path.basename(x) for x in glob.glob("./data/objects/*.jpg")]
basenamesNotEmpty = []

for name in basenames:
    if "empty" not in name:
        basenamesNotEmpty.append(name)

train = random.sample(basenames, len(basenames))
valid = random.sample(basenamesNotEmpty, 900)

with open("./val.txt","w") as f:
    for name in valid:
        f.write("data/objects/"+name+"\n")

with open("./train.txt","w") as f:
    for name in train:
        if name not in valid:
            f.write("data/objects/"+name+"\n")

```

7. Tạo tệp có tên *obj.data* chứa tên các class.

```

classes = 6
train = train.txt
valid = val.txt
names = obj.names
backup = backup/

```

8. Vào đường dẫn này để tải tệp tin trọng số cho các lớp tích chập được huấn luyện từ mạng Imagenet. Sau đó sao chép tệp tin vừa tải về vào thư mục *darknet*. Tệp tin trọng số *darknet53.conv.74* đã được huấn luyện qua hàng triệu hình nên các trọng số ở các lớp tích chập đã được tối ưu để trích xuất đặc trưng từ hình ảnh. Do vậy ta sẽ tái sử dụng các trọng số ở các lớp tích chập của từ tệp tin trọng số này và chỉ huấn luyện các trọng số ở lớp kết nối đầy đủ cho bài toán của luận văn. Đây là cách làm rất phổ biến vì cho phép kế thừa hiệu năng nhận diện rất tốt của YOLO vào nhiều bài toán nhận diện khác nhau.

<https://pjreddie.com/media/files/darknet53.conv.74>

9. Nén thư mục làm việc lại thành một tệp tin *zip*, tạo một thư mục tên *Darknet* trên *Google Drive* và upload tệp tin đã nén vào thư mục này. Đồng thời tạo một thư mục con có tên *backup* trong *Darknet*.

10. Trong *Google Colab*, chọn *Runtime* → *Change runtime type* → *Hardware accelerator* → *GPU*, chạy đoạn code sau để *build Darknet*.

```
from google.colab import drive
drive.mount('/content/drive')
%cd /content
!unzip /content/drive/'My Drive'/Darknet/darknet.zip
%cd /content/darknet
!sudo apt-get install dos2unix
!make
!chmod +x ./darknet
!rm /content/darknet/backup -r
!ln -s /content/drive/'My Drive'/Darknet/backup /content/darknet
%cd /content/darknet
!find . -type f -name "*.txt" -print0 | xargs -0 dos2unix
```

11. Dối với lần đầu tiên ta sẽ chạy dòng lệnh sau.

```
!./darknet detector train obj.data yolov3.cfg darknet53.conv.74
```

Dối với các lần huấn luyện sau ta chỉ cần dùng tệp tin *yolov3\_last.weights* để huấn luyện tiếp mà không cần huấn luyện lại từ đầu.

```
!./darknet      detector      train      obj.data      yolov3.cfg
./backup/yolov3_last.weights
```

12. *Darknet* sẽ tự động lưu các tệp tin trọng số mỗi 1000 *iteration* ví dụ: *yolov3\_1000.weights*, *yolov3\_2000.weights*. Ta có thể dừng việc huấn luyện để kiểm tra các tham số hiệu năng của mô hình như *precision* và *recall*. Việc kiểm tra này được thực hiện trên tập dữ liệu validate trong tệp *val.txt*. Để thực hiện việc kiểm tra này ta sẽ chạy dòng lệnh sau.

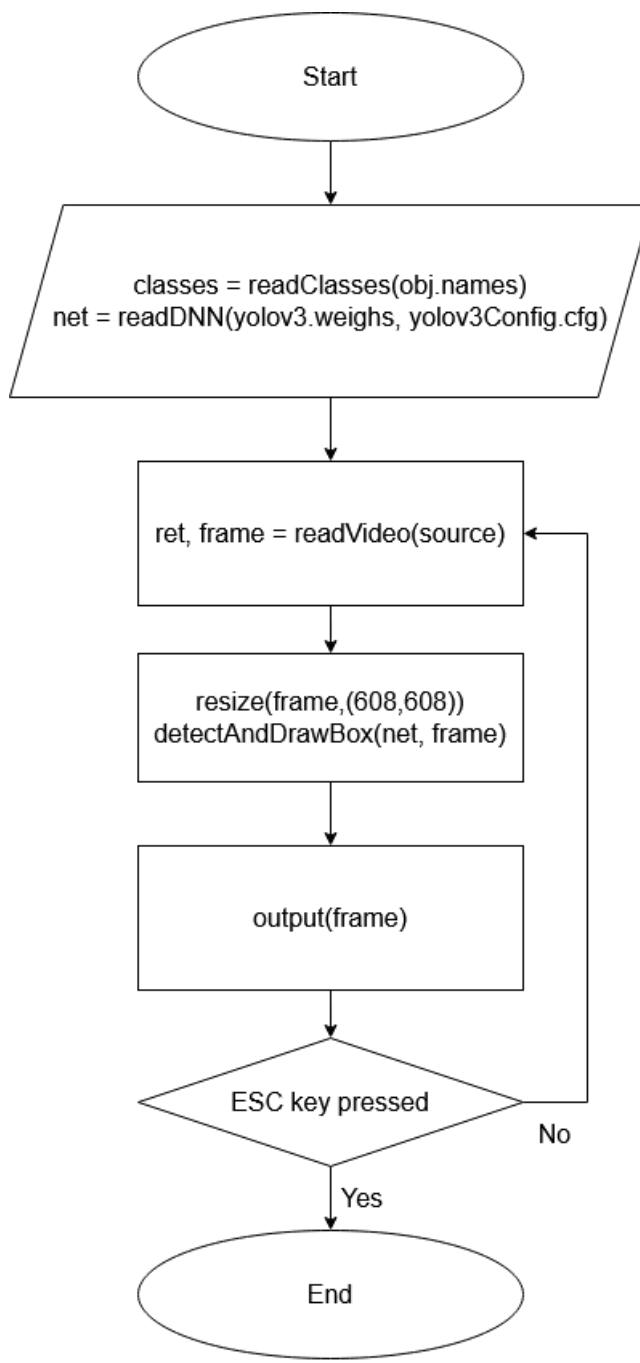
```
!./darknet      detector      map      obj.data      yolov3.cfg
./backup/yolov3_1000.weights
```

Ta có thể thay *yolov3\_1000.weights* bằng tệp tin trọng số mà ta muốn kiểm tra.

### 3.3 Sử dụng Python và mô hình mạng học sâu đã huấn luyện để nhận diện việc sử dụng trang thiết bị bảo hộ cá nhân trên camera hoặc video

Sau khi việc huấn luyện đã hoàn thành, ta sẽ dùng tệp tin trọng số để tiến hành nhận diện trên video hoặc camera. Để làm được điều này ta sẽ viết một chương trình Python có sơ đồ khống như hình 3.5.

- Chương trình sẽ lấy tên các class được định nghĩa sẵn trong tệp tin *obj.names*, đồng thời sẽ đọc các giá trị trọng số của mô hình trong tệp tin *yolov3.weights*



Hình 3.5: Sơ đồ khái quát chương trình Python để nhận dạng trên video hoặc webcam.

dựa trên các thông số về kiến trúc đã cài đặt trong tệp tin *yolov3Config.cfg*. Hàm để đọc mô hình DNN trong OpenCV là *cv2.dnn.readNet(weightsFile, configFile)* với *weightsFile* là tệp tin trọng số và *configFile* là tệp tin kiến trúc của mạng.

2. Sau đó ta sẽ dùng hàm đọc video của OpenCV để đọc dữ liệu từ webcam. Đầu tiên ta sẽ khởi tạo một đối tượng đại diện cho webcam *cap = VideoCapture(0)*. Sau đó ta sẽ đọc từng frame từ đối tượng vừa được khởi tạo *ret, image = cap.read()* với *image* là biến chứa một frame, *ret* sẽ có giá trị *True* nếu có frame được đọc từ đầu vào và *False* nếu không có frame được đọc từ đầu vào.

3. Để tiến hành nhận dạng trên hình, ta sẽ dùng các câu lệnh sau.

```
blob = cv2.dnn.blobFromImage(image, scale, (604, 604), (0, 0, 0),
    True, crop=False)
net.setInput(blob)
outs = net.forward(get_output_layers(net))
```

Dòng lệnh đầu tiên sẽ resize hình về kích thước  $(604, 604)$ , hiện nay các camera quan sát thường có độ phân giải 2MP với kích thước khung hình  $1920 \times 1080$  nên việc resize về  $604 \times 604$  sẽ không làm mất đi các đặc trưng quan trọng và cho phép giảm thiểu số lượng tính toán để việc dự đoán trên hình nhanh hơn và tốn ít tài nguyên phần cứng hơn. Sau đó từng pixel trong hình sẽ được trừ cho  $(0, 0, 0)$  và chia cho  $scale$ .  $swapRB=True$  sẽ hoán đổi vị trí hai kênh đỏ và xanh dương trong tensor của hình.  $crop=False$  sẽ không crop hình sau khi resize. Giả sử kênh màu đỏ của hình sau khi được resize có giá trị là  $R$ ,  $scale=\sigma$ , giá trị để trừ là  $\mu_{red}$ , giá trị của kênh màu đỏ sau khi đi qua hàm  $blob$  sẽ là

$$\frac{R - \mu_{red}}{\sigma} \quad (3.1)$$

Kết quả của hàm  $blob$  sẽ được đưa vào đối tượng  $net$  và đầu ra sẽ là kết quả của quá trình feed forward.

4. Tuy nhiên tại đầu ra  $outs$  sẽ có rất nhiều bounding box bị trùng lặp do với cùng một vật thể và class. Do đó kết quả đầu ra cần phải đi qua giải thuật non-maximum suppression để có thể lấy một bounding box riêng biệt và duy nhất cho một vật thể.

Về cơ bản giải thuật non-maximum suppression hoạt động như sau.

- (a) Bắt đầu giải thuật có sẽ có hai mảng một chiều A và B với mảng A chứa các bounding box cần xử lý, mảng B rỗng.
- (b) Lấy bounding box có giá trị  $confidence$  lớn nhất trong A và đưa vào B và loại bounding box này ra khỏi A.
- (c) Với mọi bounding box còn lại trong A, tìm IOU với bounding box vừa đưa vào B. Nếu IOU lớn hơn ngưỡng  $nmsThreshold$  thì loại bounding box đang xét ra khỏi A.
- (d) Lặp lại bước (b) và (c) cho đến khi không còn bounding box nào trong A.

```
indices = cv2.dnn.NMSBoxes(boxes, confidences, confThreshold, nm-
sThreshold)
```

5. Cuối cùng, ta sẽ vẽ các bounding box vào frame và xuất ra màn hình.

```

for i in indices:
    i = i[0]
    box = boxes[i]
    x = box[0]
    y = box[1]
    w = box[2]
    h = box[3]
    image = draw_prediction(image, class_ids[i], confidences[i],
    round(x), round(y), round(x + w), round(y + h))

cv2.imshow("test", image)

```

Chương trình Python để sau cùng để nhận diện trên webcam.

```

from PIL import Image
import time
import cv2
import argparse
import numpy as np

def get_output_layers(net):
    layer_names = net.getLayerNames()

    output_layers = [layer_names[i[0] - 1] for i in
    net.getUnconnectedOutLayers()]

    return output_layers

def draw_prediction(img, class_id, confidence, x, y, x_plus_w,
y_plus_h):
    label = str(classes[class_id])

    if class_id == 5 or class_id == 3 or class_id == 1:
        color = [0,0,255]
    else:
        color = COLORS[class_id]

    cv2.rectangle(img, (x, y), (x_plus_w, y_plus_h), color, 2)

    if class_id == 5 or class_id == 4:
        cv2.putText(img, label, (x - 10, y - 35),
        cv2.FONT_HERSHEY_SIMPLEX, 1, color, 1)
    else:
        cv2.putText(img, label, (x - 10, y - 10),
        cv2.FONT_HERSHEY_SIMPLEX, 1, color, 1)

    return img

```

```
def eudistance(v1, v2):
    dist = [(a - b)**2 for a, b in zip(v1, v2)]
    dist = math.sqrt(sum(dist))
    return dist

# Create a VideoCapture object
cap = cv2.VideoCapture(0)

# Check if camera opened successfully
if (cap.isOpened() == False):
    print("Unable to read camera feed")

# Default resolutions of the frame are obtained. The default
resolutions are system dependent.
# We convert the resolutions from float to integer.
frame_width = int(cap.get(3))
frame_height = int(cap.get(4))

classes = []
with open("obj.names", 'r') as f:
    classes = [line.strip() for line in f.readlines()]

COLORS=[[0,128,0],[255,0,0],[255,165,0],[0,0,255],[255,255,0],[255,69,0]]

net = cv2.dnn.readNet("yolov3-tiny_12000.weights", "yolov3-
tiny.cfg")

conf_threshold = 0.2
nms_threshold = 0.4

Width = frame_width
Height = frame_height
scale = 0.00392
```

```
start = time.time()
count = 0
while(True):
    ret, image = cap.read()

    if ret == True:
        if count
            blob = cv2.dnn.blobFromImage(image, scale, (604, 604), (0,
0, 0), True, crop=False)

            net.setInput(blob)

            outs = net.forward(get_output_layers(net))

            class_ids = []
            confidences = []
            boxes = []
            class_ids_mask = []
            confidences_mask = []
            boxes_mask = []
            class_ids_hat = []
            confidences_hat = []
            boxes_hat = []

        for out in outs:
            for detection in out:
                scores = detection[5:]
                class_id = np.argmax(scores)
                confidence = scores[class_id]
                if class_id == 0 or class_id == 1 or class_id == 4
or class_id == 5:
                    mask_id = 0
                    hat_id = 0

                    if float(scores[0]) > float(scores[1]):
                        hat_id = 0
                    else:
                        hat_id = 1
```

```

if float(scores[4]) > float(scores[5]):
    mask_id = 4
else:
    mask_id = 5

if confidence > 0.25:
    center_x = int(detection[0] * Width)
    center_y = int(detection[1] * Height)
    w = int(detection[2] * Width)
    h = int(detection[3] * Height)
    x = center_x - w / 2
    y = center_y - h / 2

    class_ids_mask.append(mask_id)
    confidences_mask.append(float(scores[hat_id]))
    boxes_mask.append([x, y, w, h])

    class_ids_hat.append(hat_id)
    confidences_hat.append(float(scores[hat_id]))
    boxes_hat.append([x, y, w, h])

else:
    if confidence > 0.25:
        center_x = int(detection[0] * Width)
        center_y = int(detection[1] * Height)
        w = int(detection[2] * Width)
        h = int(detection[3] * Height)
        x = center_x - w / 2
        y = center_y - h / 2
        class_ids.append(class_id)
        confidences.append(float(scores[class_id]))
        boxes.append([x, y, w, h])

    indices      = cv2.dnn.NMSBoxes(boxes,      confidences,
conf_threshold, nms_threshold)
    indices_mask = cv2.dnn.NMSBoxes(boxes_mask, confidences_mask,
conf_threshold, nms_threshold)

```

```
    indices_hat = cv2.dnn.NMSBoxes(boxes_hat, confidences_hat, conf_threshold, nms_threshold)

    for i in indices:
        i = i[0]
        box = boxes[i]
        x = box[0]
        y = box[1]
        w = box[2]
        h = box[3]
        image = draw_prediction(image, class_ids[i], confidences[i],
                                round(x), round(y), round(x + w), round(y + h))

    for i in indices_mask:
        i = i[0]
        if class_ids_mask[i] == 5:
            noMask = True
        else:
            noMask = False
        box = boxes_mask[i]
        x = box[0]
        y = box[1]
        w = box[2]
        h = box[3]
        image = draw_prediction(image, class_ids_mask[i], confidences_mask[i],
                                round(x), round(y), round(x + w), round(y + h))
```

```

for i in indices_hat:
    i = i[0]
    if class_ids_hat[i] == 1:
        noHat = True
    else:
        noHat = False
    box = boxes_hat[i]
    x = box[0]
    y = box[1]
    w = box[2]
    h = box[3]
    image = draw_prediction(image, class_ids_hat[i], confidences_hat[i], round(x), round(y), round(x + w), round(y + h))

    cv2.putText(image, "FPS: " + str(round(count/(time.time()-start))), (30, 30), cv2.FONT_HERSHEY_SIMPLEX, 1, [0,255,0], 1)
    # Show webcam
    cv2.imshow("test", image)

    k = cv2.waitKey(1)
    if k
        # ESC pressed
        print("Escape hit, closing...")
        break
    count+=1

cap.release()
cv2.destroyAllWindows()

end = time.time()
print("YOLO Execution time: " + str(end-start))

```

Chương *Phương pháp tiếp cận* đã trình bày các bước để ứng dụng mô hình mạng neuron tích chập YOLOv3 để giải quyết bài toán nhận diện trang phục bảo hộ lao động. Bắt đầu từ việc xây dựng tập dữ liệu theo format của YOLO, sau đó huấn luyện sử dụng framework darknet, sau cùng là sử dụng mô hình đã huấn luyện được vào chương trình Python. Tuy nhiên, đối với các bài toán ứng dụng trí tuệ nhân tạo, việc đánh giá các thông số hiệu năng của mô hình là vô cùng quan trọng, do vậy chương sau sẽ được dành để đánh giá các thông số hiệu năng của mô hình đã được huấn luyện.

## Chương 4

# Đánh giá các thông số hiệu năng của mô hình nhận diện trang thiết bị bảo hộ

Mô hình được huấn luyện trong ba ngày với 12000 iteration. Trong quá trình huấn luyện, việc tính toán các thông số hiệu năng của mô hình được thực hiện với mỗi 1000 iteration trên tập dữ liệu validation. Nhắc lại về cách tính các thông số hiệu năng:

- Precision là thông số thể hiện độ chính xác của các dự đoán. *TruePositive* (viết tắt: TP) là những bounding box được dán nhãn đúng và thực sự đúng. *FalsePositive* (viết tắt: FP) là những bounding box được dán nhãn đúng và không thực sự đúng. Precision được tính bằng công thức

$$precision = \frac{TP}{TP + FP} \quad (4.1)$$

- Recall là thông số thể hiện độ nhạy của mô hình với các đối tượng cần nhận dạng. *TruePositive* (viết tắt: TP) là những bounding box được dán nhãn đúng và thực sự đúng. *FalseNegative* (viết tắt: FN) là những bounding box được dán nhãn không đúng hoặc không được dán nhãn và thực sự đúng. Recall được tính bằng công thức

$$precision = \frac{TP}{TP + FN} \quad (4.2)$$

- Average precision là thông số được tính cho một class. Với mỗi class, trong quá trình đánh giá trên tập dữ liệu validation, các giá trị precision và recall sẽ được lưu lại. Sau đó ta sẽ vẽ đồ thị của precision theo recall, average precision của một class sẽ là phần diện tích dưới đồ thị này. Gọi  $p(r) : [0, 1] \rightarrow [0, 1]$  là hàm số biểu diễn quan hệ của precision và recall. Average precision của một class sẽ được tính theo công thức

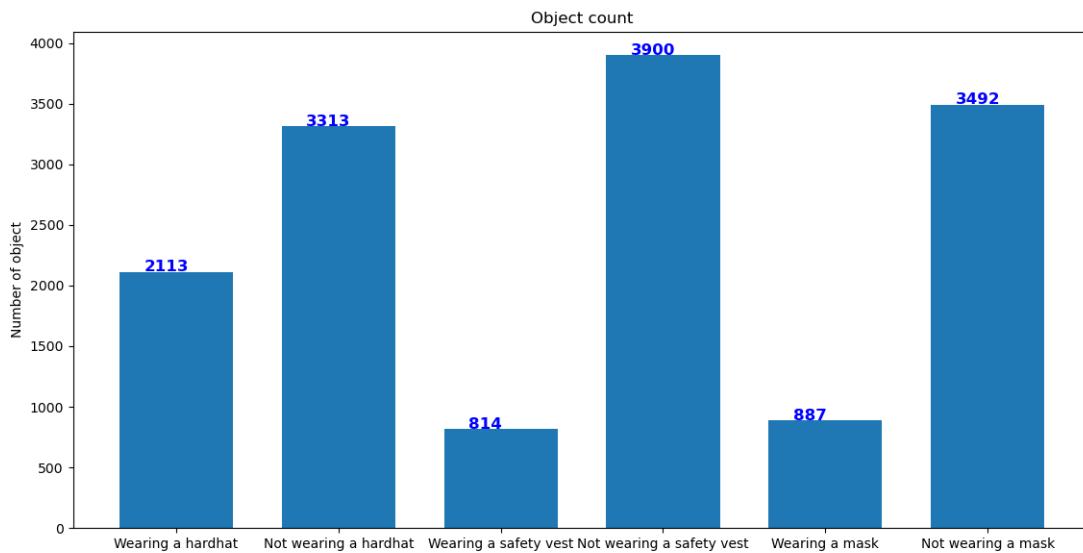
$$\text{average precision} = \int_0^1 p(r)dr \quad (4.3)$$

- Mean average precision là trung bình của các average precision của các class

$$\text{mean average precision} = \frac{\sum_{i=0}^N ap_i}{N} \quad (4.4)$$

Với  $N \in \mathbb{N}^*$  là số class của mô hình.

Tập dữ liệu validation gồm 900 hình được chia một cách ngẫu nhiên từ tập dữ liệu gốc và không được dùng để huấn luyện, số lượng các object trong tập dữ liệu này được thể hiện trong hình 4.1

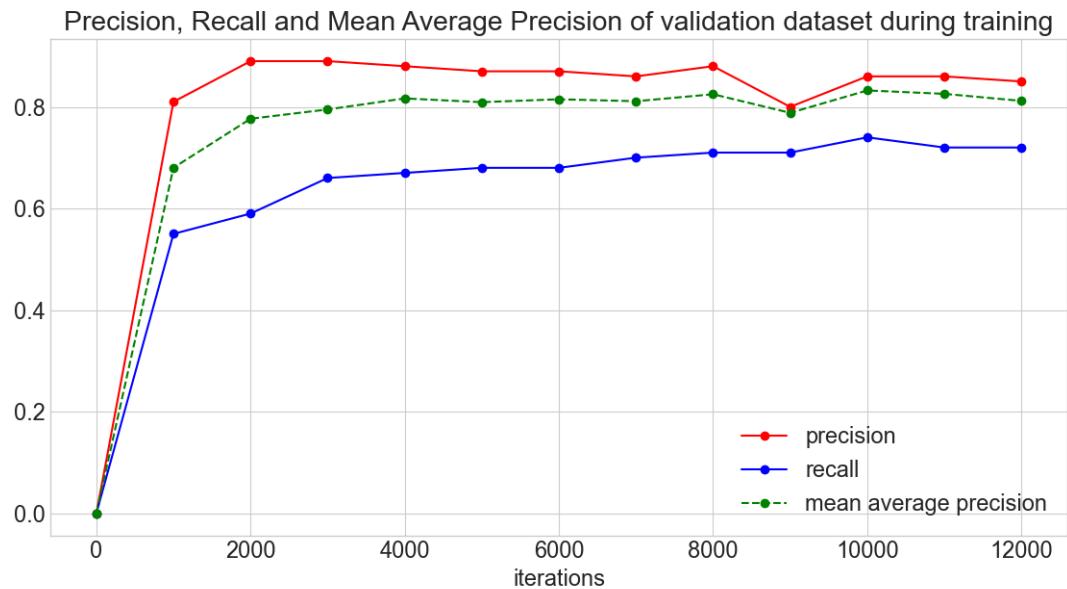


Hình 4.1: Số lượng các object trong tập dữ liệu validation. Wearing a hardhat - 2113, Not wearing a hardhat - 3313, Wearing a safety vest - 814, Not wearing a safety vest - 3900, Wearing a mask - 887, Not wearing a mask - 3492.

Các thông số được tính toán gồm: precision, recall và mean average precision 4.2. Ta thấy rằng với số lượng dữ liệu từ tập huấn luyện, mô hình cho hiệu năng tốt nhất trên tập validation ở 10000 iteration. Khi tham khảo ở các diễn đàn trên Internet cũng như từ những người trực tiếp xây dựng framework darknet, số lượng iteration tối đa thường sẽ được gọi ý là số class  $C$  nhân với 2000. Đối với mô hình này số iteration lý tưởng là 12000. Tuy nhiên dựa vào kết quả trên tập validation ta thấy rằng các thông số hiệu năng của mô hình tại 10000 iteration cao hơn rất nhiều so với tại 12000. Do vậy trong quá trình huấn luyện các mô hình mạng học sâu thì phương pháp dừng tốt nhất vẫn là thường xuyên kiểm tra hiệu năng của mô hình trên một tập validation để phát hiện điểm tối ưu.

#### 4.0.1 Thủ nghiệm mô hình trong các trường hợp thực tế

Việc đánh giá mô hình trên tập dữ liệu validation cũng phần nào phản ánh được các thông số hiệu năng của mô hình, tuy nhiên để có thể có những đánh giá trực quan hơn, cần thiết phải có những kiểm nghiệm thực tế. Các bài kiểm tra sau được thực hiện trong các điều kiện và hoàn cảnh khác nhau nhằm khảo sát



Hình 4.2: Precision - màu đỏ, Recall - màu xanh dương, Mean Average Precision - màu xanh lá. Các thông số được tính toán mỗi 1000 iteration trên tập dữ liệu validation.

khả năng dự đoán của mô hình trong các trường hợp có thể xảy ra. Mỗi trường hợp sẽ được chụp một số hình ảnh nhất định, sau đó sẽ tiến hành dùng mô hình để dự đoán trên các hình ảnh này, sau cùng là đánh giá các thông số hiệu năng của mô hình trong các trường hợp. Các hình ảnh được chụp từ camera có khẩu độ f 4.0, tiêu cự 14 mm.

### **Khảo sát về precision và recall của mô hình khi khoảng cách từ camera đến các chủ thể thay đổi**

Trong thử nghiệm này các chủ thể sẽ đứng lần lượt ở các khoảng cách 3m - hình 4.3, 6m - hình 4.4 và 9m - hình 4.5 so với camera. Ngoài ra sẽ có một chủ thể sử dụng nón vải màu trắng, gần giống với nón bảo hiểm màu trắng - hình 4.6 và hình 4.7 để kiểm nghiệm khả năng phân biệt các vật thể gần giống nhau của mô hình.

*Kết quả:* Đồ thị precision ở hình 4.8 và recall ở hình 4.9 cho thấy mô hình hoạt động tốt nhất ở khoảng cách 6m. Các thông số precision và recall của hầu hết các class ở 6m đều trội hơn so với ở 3m và 9m. Việc precision cao sẽ giúp các dự đoán của mô hình tại 6m chính xác hơn so với tại 3m và 9m. Recall cao nói lên rằng mô hình sẽ nhạy hơn và có thể phát hiện được nhiều vật thể hơn trong một khung hình tại khoảng cách 6m. Tại class *Not wearing a hardhat* có sự dao động về thông số hiệu năng và kết quả dự đoán ở khoảng cách 6m vẫn chưa là tốt nhất điều này có thể xuất phát từ việc các bounding box của class *Not wearing a hardhat* trong tập dữ liệu huấn luyện có kích thước gần tương đồng với các bounding box của vật thể cùng class ở khoảng cách 9m.

Ngoài ra, mô hình cũng có thể phân biệt tốt giữa nón vải trắng và nón bảo hộ trắng tại khoảng cách 3m như trên hình 4.10 và 4.11. Tại 6m mô hình vẫn tiếp tục phân biệt tốt như trên hình 4.12 và 4.13. Độ chính xác giảm xuống khi chủ



Hình 4.3: Các chủ thể đứng cách camera ở khoảng cách 3m.



Hình 4.4: Các chủ thể đứng cách camera ở khoảng cách 6m.



Hình 4.5: Các chủ thể đứng cách camera ở khoảng cách 9m.



Hình 4.6: Một chủ thể đội nón vải trắng - bên trái và một chủ thể đội nón bảo hiểm trắng - bên phải. Góc chụp trực diện



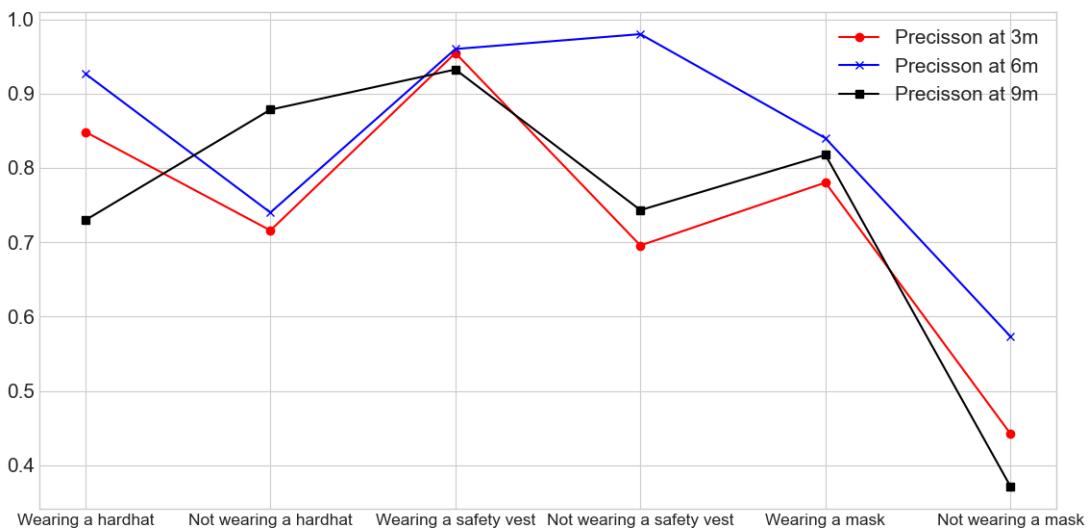
Hình 4.7: Một chủ thể đội nón vải trắng - bên trái và một chủ thể đội nón bảo hiểm trắng - bên phải. Góc chụp từ trái qua

thể cách xa camera 9m như trên hình 4.14 và 4.15.

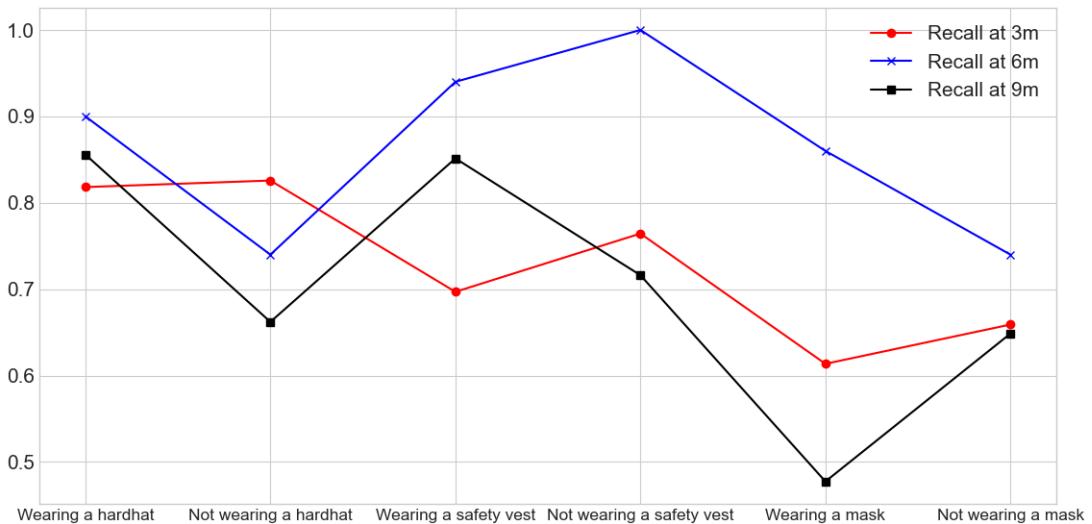
### Thử nghiệm khả năng nhận diện của mô hình với các trường hợp sử dụng sai cách các thiết bị bảo hộ

Việc sử dụng các thiết bị bảo hộ sai cách cũng nguy hiểm giống như việc không sử dụng thiết bị bảo hộ, do đó không chỉ cần phân biệt giữa có sử dụng hay không mà mô hình còn phải có thể phân biệt được giữa sử dụng đúng và sai trang thiết bị bảo hộ. Trong trường hợp này, chủ thể sẽ đeo khẩu trang sai cách hoặc mặc áo phản quang sai cách để kiểm tra khả năng nhận diện của mô hình.

*Trường hợp 1:* Việc đeo khẩu trang sai cách sẽ được thực hiện thông qua hai trường hợp, một là đeo khẩu trang hở mũi - hình 4.16, hai là đeo khẩu trang hở miệng - hình 4.17. Các kết quả dự đoán được thực hiện trên hình ở khoảng cách 3m. *Kết quả:* Mô hình không thể phân biệt được trường hợp đeo khẩu trang sai



Hình 4.8: Precision của các class tại các khoảng cách 3m - màu đỏ, 6m - màu xanh và 9m - màu đen. Cao hơn nghĩa là tốt hơn.



Hình 4.9: Recall của các class tại các khoảng cách 3m - màu đỏ, 6m - màu xanh và 9m - màu đen. Cao hơn nghĩa là tốt hơn.

khi chủ thẻ đeo khẩu trang để hở mũi - hình 4.18. Mô hình có thể phân biệt tốt trong trường hợp đeo khẩu trang sai khi chủ thẻ đeo khẩu trang hở miệng - hình 4.19.

*Trường hợp 2:* Việc mặc áo bảo hộ sai cách sẽ được thực hiện bằng cách chỉ đặt áo lên người mà không thật sự mặc hoặc mặc nhưng không cài vào đúng cách như trong hình 4.20, việc này có thể khiến áo dễ mắc vào các thiết bị phương tiện đang hoạt động và gây ra các tai nạn đáng tiếc. Các kết quả dự đoán được



Hình 4.10: Dự đoán của mô hình ở khoảng cách 3m.



Hình 4.11: Mô hình có thể phân biệt tốt giữa nón vải trắng và nón bảo hiểm trắng ở khoảng cách 3m.

thực hiện trên hình ở khoảng cách 3m. *Kết quả:* Mô hình có thể phân biệt được các trường hợp mặc sai áo bảo hộ ở phần lớn các trường hợp như trên hình 4.21 và 4.22. Tuy nhiên ở một vài góc chụp như trên hình 4.23 thì mô hình không thể nhận diện được chính xác. Điều này có thể không phải là nhược điểm lớn vì khi nhận diện trong thực tế thì mô hình sẽ nhận diện liên tục qua nhiều khung hình do đó những trường hợp mặc sai khi bị bỏ qua ở khung hình này thì sẽ được phát hiện trong khung hình khác.



Hình 4.12: Dự đoán của mô hình ở khoảng cách 6m.



Hình 4.13: Mô hình có thể phân biệt tốt giữa nón vải trắng và nón bảo hiểm trắng ở khoảng cách 6m.



Hình 4.14: Dự đoán của mô hình ở khoảng cách 9m.

### Thử nghiệm khả năng nhận diện của mô hình khi chủ thể đứng sau vật cản

Trong thử nghiệm này, hai chủ thể sẽ đứng sau một vật cản là cánh cửa sắt như trên hình 4.24, các thông số precision và recall của mô hình sẽ được tính



Hình 4.15: Mô hình không thể phân biệt tốt giữa nón vải trắng và nón bảo hiểm trắng ở khoảng cách 9m.



Hình 4.16: Chủ thẻ (bên trái) đeo khẩu trang không che kín mũi ở khoảng cách 3m.

toán dựa trên kết quả dự đoán của mô hình trên các hình chụp ở khoảng cách 3m và 6m.

*Kết quả:* Các giá trị precision - hình 4.25 và recall - hình 4.26 của mô hình khi dự đoán với chủ thẻ đứng sau vật cản là rất thấp tại khoảng cách 3m và 6m. Điều này chứng tỏ mô hình không thể dùng để nhận diện trong các trường hợp bị vướng vật cản.



Hình 4.17: Chủ thẻ (bên trái) đeo khẩu trang không che kín miệng ở khoảng cách 3m.



Hình 4.18: Kết quả dự đoán không tốt với chủ thẻ (bên trái) đeo khẩu trang không che kín mũi ở khoảng cách 3m.



Hình 4.19: Kết quả dự đoán tốt với chủ thẻ (bên trái) đeo khẩu trang không che kín miệng ở khoảng cách 3m.



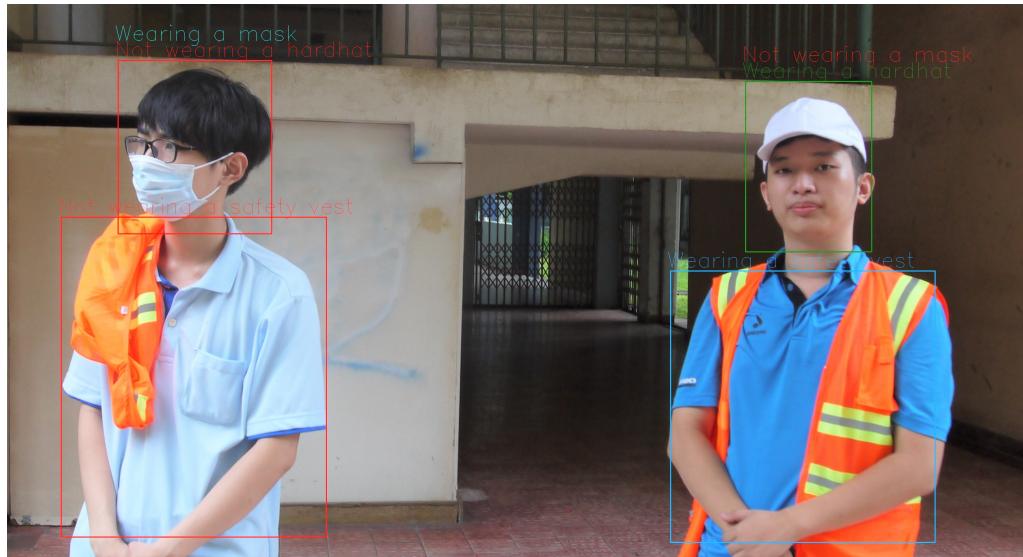
Hình 4.20: Hai chủ thẻ (bên trái ngoài cùng) mặc áo bảo hộ sai cách ở khoảng cách 3m.



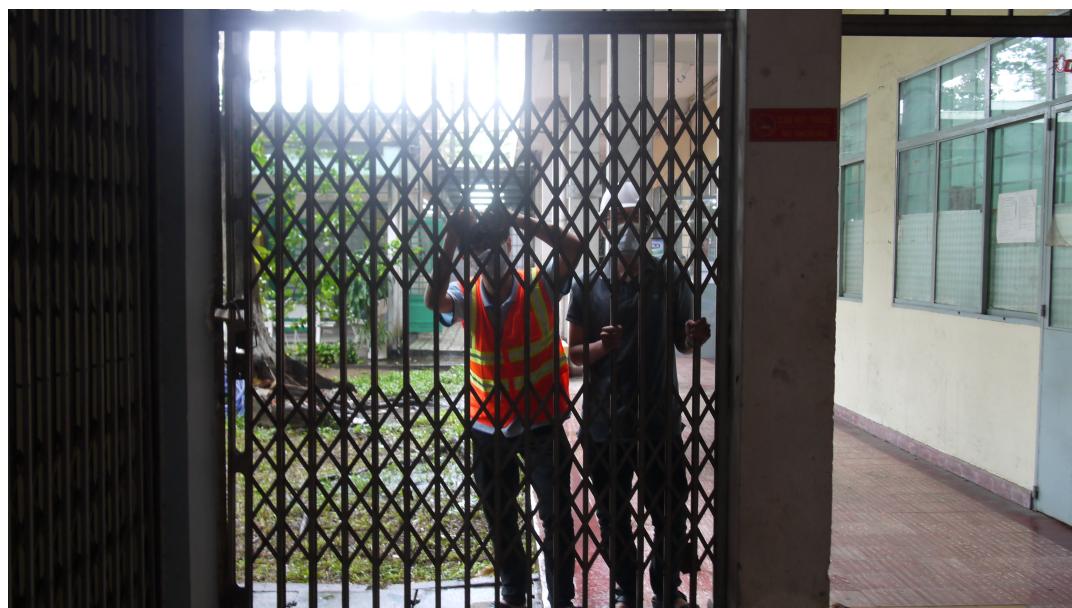
Hình 4.21: Kết quả dự đoán tốt với hai chủ thẻ mặc áo bảo hộ sai cách ở khoảng cách 3m.



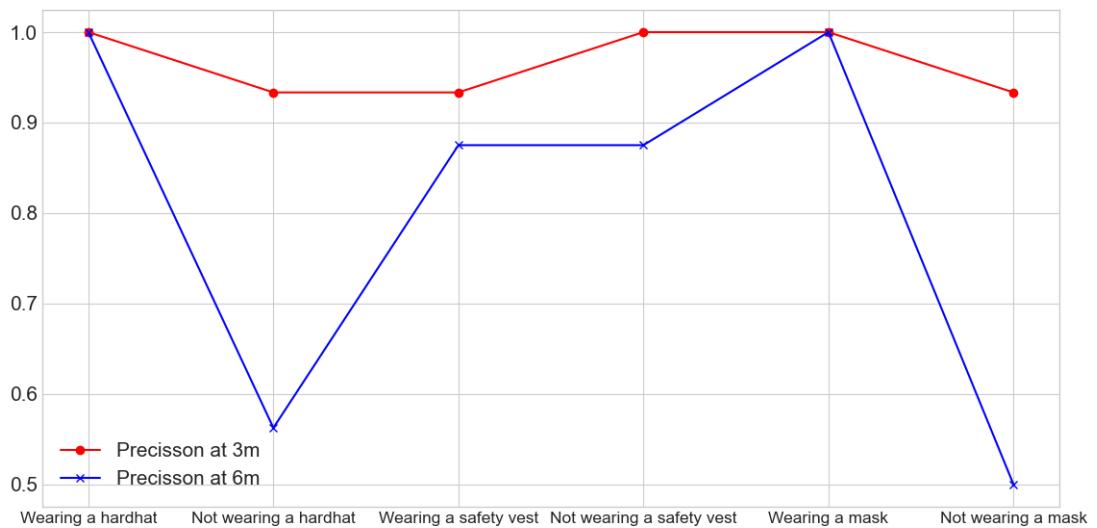
Hình 4.22: Kết quả dự đoán tốt với hai chủ thẻ mặc áo bảo hộ sai cách (góc máy khác) ở khoảng cách 3m.



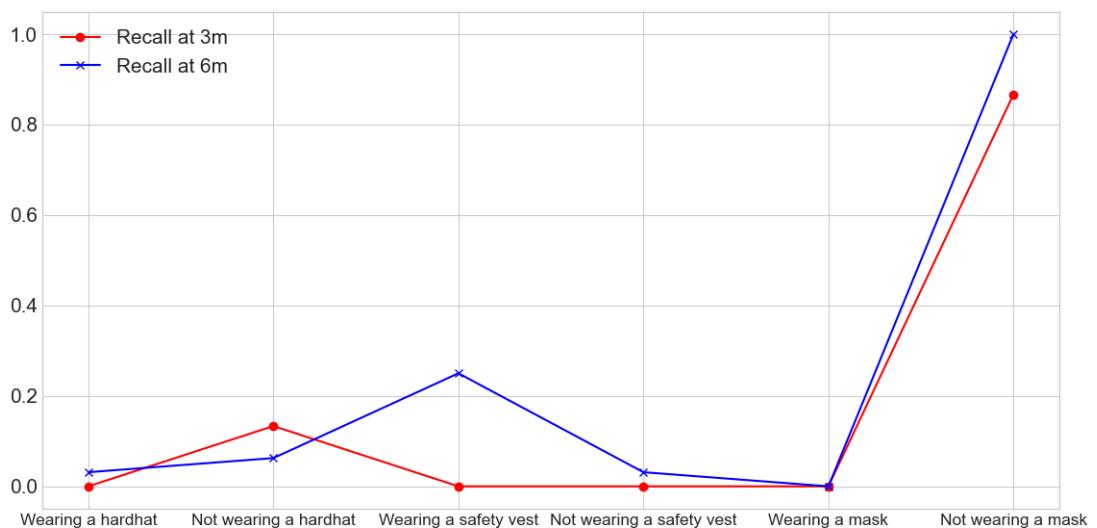
Hình 4.23: Kết quả dự đoán không tốt với hai chủ thể mặc áo bảo hộ sai cách ở khoảng cách 3m.



Hình 4.24: Hai chủ thể đứng sau vật cản ở khoảng cách 3m.



Hình 4.25: Precision của các class khi các chủ thể đứng sau vật cản và cách camera tại các khoảng cách 3m - màu đỏ và 6m - màu xanh.



Hình 4.26: Recall của các class khi các chủ thể đứng sau vật cản và cách camera tại các khoảng cách 3m - màu đỏ và 6m - màu xanh.

# Chương 5

## Kết luận về khả năng nhận diện việc sử dụng trang thiết bị bảo hộ của mô hình và hướng phát triển

### 5.1 Kết luận về khả năng nhận diện việc sử dụng trang thiết bị bảo hộ của mô hình

Luận văn này đã xây dựng thành công hệ thống giám sát việc sử dụng thiết bị bảo hộ cá nhân trên cơ sở lý thuyết mạng neuron tích chập. Hệ thống sử dụng mô hình YOLOv3 được huấn luyện từ đầu trên tập dữ liệu tự xây dựng với tổng cộng 11586 hình với nhiều khung cảnh và thời gian khác nhau để đảm bảo mô hình không quá quen thuộc với một ngữ cảnh nhất định. Sau khi thử nghiệm mô hình trong thực tế có thể rút ra được các kết luận sau về khả năng nhận diện của mô hình:

- Mô hình có khả năng dự đoán tương đối tốt với độ chính xác trung bình giữa các class xấp xỉ 84% và độ nhạy xấp xỉ 86% tại khoảng cách 6m. Khi khoảng cách tăng dần hoặc giảm dần thì khả năng nhận diện của mô hình bắt đầu giảm.
- Mô hình có thể được dùng để phát hiện các trường hợp sử dụng sai nón bảo hộ, áo bảo hộ hoặc khẩu trang. Tuy nhiên khả năng nhận diện của mô hình trong các trường hợp này còn hạn chế và phụ thuộc nhiều vào góc quay của camera và tư thế của chủ thẻ trong khung hình.
- Nếu như giữa chủ thẻ và camera có vật cản che đi một phần của chủ thẻ thì mô hình không thể được dùng để nhận diện được trong các trường hợp này.
- Tốc độ xử lý của mô hình còn chậm, mô hình mất 0.712 giây để dự đoán trên một hình với máy tính có CPU Intel Core i5-6300U @ 2.40GHz, RAM 8.00 GB. Khi thực hiện nhận diện trên webcam của máy tính thì mô hình chạy với tốc độ là 0.4 frame/s.

## 5.2 Hướng phát triển

Vấn đề đảm bảo an toàn lao động luôn nhận được sự chú ý của xã hội, việc cải thiện khả năng giám sát trong các khu vực cần đảm bảo việc trang bị các thiết bị bảo hộ lao động sẽ giúp nâng cao chất lượng môi trường làm việc không chỉ trong ngành xây dựng mà còn các ngành có rủi ro tai nạn cao khác như hầm mỏ, chế tạo sắt,... Để có thể thực sự đáng tin cậy để có thể dùng trong thực tế hệ thống cần phải đảm bảo độ chính xác trên 95%. Nhằm đạt được mục tiêu này một số hướng tiếp cận có thể được thực hiện:

- Tăng số lượng ảnh trong tập dữ liệu với nhiều background khác nhau để mô hình có thể học được nhiều trường hợp đặc biệt hơn.
- Dùng các kiến trúc mạng tích chập mới hơn như YOLOv4 để tăng độ chính xác.
- Xây dựng hệ thống phần cứng mang tính tối ưu cho mạng neuron tích chập để có thể chạy mô hình trong thời gian thực.

# Tài liệu tham khảo

- [1] Bộ Lao động - Thương binh và Xã hội. Thông báo tình hình tai nạn lao động năm 2019, 2019.
- [2] D. O. Hebb. *The organization of behavior: A neuropsychological theory*. Wiley, 1949.
- [3] Arthur Lee Samuel. Some Studies in Machine Learning Using the Game of Checkers. *IBM Journal of Research and Development*, page 44:206–44:226, 1959.
- [4] David E. Rumelhart, Geoffrey E. Hinton and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, page 533–536, 1986.
- [5] Y. LeCun, L. Bottou, Y. Bengio and P. Haffner. Gradient-Based Learning Applied to Document Recognition. *Proceedings of the IEEE*, pages 86(11):2278–2324, 1998.
- [6] Suzana Herculano-Houzel. The Human Brain in Numbers: A Linearly Scaled-up Primate Brain. *Frontiers in Human Neuroscience*, pages 3:31:1–3:31:11, 2009.
- [7] Alex Krizhevsky, Ilya Sutskever, Geoffrey E. Hinton. ImageNet Classification with Deep Convolutional Neural Networks. *LSVRC*, 2012.
- [8] Vũ Hữu Tiệp. *Machine Learning cơ bản*. Nhà Xuất Bản Khoa học & kỹ thuật, 2020.
- [9] Standford University. Convolutional neural networks (cnns / convnets), 2020.
- [10] Nguyễn Thanh Tuán. *Deep Learning cơ bản*. 2019.
- [11] Joseph Redmon, Santosh Divvala, Ross Girshick, Ali Farhadi. You Only Look Once: Unified, Real-Time Object Detection. *CVPR 2016*, 2016.
- [12] Joseph Redmon, Ali Farhadi. YOLOv3: An Incremental Improvement. *Tech report*, 2018.
- [13] John Syin. Hardhat and safety vest image for object detection, 2020.
- [14] Jixiu Wu, Nian Cai, Wenjie Chen, Huiheng Wang, Guotian Wang. Automatic detection of hardhats worn by construction personnel: A deep learning approach and benchmark dataset. *Automation in Construction*, 2019.
- [15] Tzutalin. Labelimg, 2018.

[16] AlexeyAB. Darknet, 2020.